

Module 2 random variable

2.1 random variable and generated σ -algebra

2.1.1 random variable: 即 prob space 上的一个 Borel measurable function

Def 2.1 (random variable)

对于 probability space $(\Omega, \mathcal{F}, \mathbb{P})$, 一个 random variable 是一个 **Borel measurable function** $X : \Omega \rightarrow \mathbb{R}$.



Remark

回顾 (Borel) measurable function 的定义: 即对于任意 $B \in \mathcal{B}(\mathbb{R})$, 有 $X^{-1}(B) \in \mathcal{F}$; 由于是在 real space 上, Borel measurable 也可以简化为: 对于任意的 open ray $(-\infty, a)$, 有 $X^{-1}((-\infty, a)) \in \mathcal{F}$.

例如: $X(\omega) = \omega^2$ 是一个 (Borel) measurable function, 因为对于任意 open ray $(-\infty, a)$, $X^{-1}((-\infty, a))$ 是一个 interval (either $(-\sqrt{a}, \sqrt{a})$ or $\emptyset$).

并且 recall: 任意的 continuous function 都是 (Borel) measurable function. (所以之后我们看到 continuous function 就知道它一定是一个 random variable).

Remark

Random variable (Borel measurable function) 本质上是对样本空间中的事件进行 weights assignment.

原本, 一个 prob space 只能表示: 有多少个 outcomes, 每个 outcome 的概率是多少 (对于无限的 sample space, 一些 outcomes 组合, 即事件, 的概率是多少).

而 random variable 就是给这些 outcomes 以 weights: 比如

Example 2.1

在一副扑克牌中抽一张, 那么每一张的概率都是 $1/52$. 但是如果我想知道抽到的牌的价值, 那么我就需要一个 random variable X 来给每一张牌赋予一个 weight; 比如说, $X(A) = 1, X(2) = 2, \dots, X(K) = 13$.

Question: 为什么对于 assigning weights 的行为, 我们一定要求它是一个 (Borel) measurable function 呢? 普通的给 outcomes 以 weights 的行为 (任意一个 function $f : \Omega \rightarrow \mathbb{R}$) 不行吗?

Answer: 因为我们想要知道 X 的值在一个范围 B , 比如 $[1, 6]$ 之内的 probability (which is defined on 原本的 prob measure $\mathbb{P}$ 上的) 是多少. 而只有每一个这样的范围集合的 preimage $X^{-1}(B)$ 都是 $\mathcal{F}$ 中的事件, 我们才能够通过 $\mathbb{P}$ 来计算这个 probability; that is, 我们需要这个 X 是一个 measurable function. 因为这一切都是建立在我们以 measure theory 的 framework 来定义 probability 的基础上的.

下面是一个简单的 proposition: 我们可以把多个 random variables 以一种 Borel measurable 的方式组合起来, 那么就成为一个新的 random variable.

Proposition 2.1 (以 Borel measurable 的方式组合起多个 random variables)

Prob space $(\Omega, \mathcal{F}, \mathbb{P})$ 上的 random variables $X_1, X_2, \dots, X_k : \Omega \rightarrow \mathbb{R}$, 任取 Borel measurable function

$$g : \mathbb{R}^k \rightarrow \mathbb{R},$$

$$X : \Omega \rightarrow \mathbb{R}$$

$$\omega \mapsto g(X_1(\omega), X_2(\omega), \dots, X_k(\omega))$$

也是一个 random variable.



Proof 我们在 measure theory 中证明过: 对于任意的 finite seq of Borel measurable functions $(f_i : \Omega \rightarrow \mathbb{R})_{i=1}^k$, 其各作为一个维度组成的函数 $f = (f_1, \dots, f_k)$ 也是一个 Borel measurable function (from Ω 到 $\mathbb{R}^k$).

而这里的 X 就是 $g \circ f$, 是两个 Borel measurable function 的 composition, 因而也是一个 Borel measurable function (即 random variable). $\square$

Remark 以一种 Borel measurable 的方式组合多个 random variables, 这个函数也仍然是一个 random variable.

这个 proposition 看似没有什么卵用, 但是它其实是我们之后构造 random variable 的一个重要工具. 很多我们默认合法的行为, 它都作为基础.

比如我们:

- 定义了两个 random variable X 和 Y , 那么它们的和 $X + Y$ 以及积 $X \cdot Y$ 也是 random variables.
- 更加复杂的: 标量变换 $g(X) = \sin(X)$, $h(X) = e^X$, 向量变换 $g(X_1, X_2) = X_1^2 + X_2^2$, 等等, 都是 random variables.

- 统计学中, 我们有一堆样本, **每一个都是随机采样得到的** (即一个 random variable X_i). 因而在观测之前, 我们把它看作一个 random variable X_i , 然后在观测之后取到它的一个实际值 x_i .

通常我们假设所有样本都是 **independent and identically distributed (i.i.d., 独立同分布)** 的, 即所有的 $X_1, X_2, \dots, X_n$ 都是 independent 的, 并且服从同一个 distribution (discuss later...).

然后, 我们就可以从这些样本中计算各种统计量, 比如平均值 $\bar{X} := \frac{1}{n} \sum_{i=1}^n X_i$, 再比如 order statistic, sample variance 等等, 从而通过大数定律等工具的辅佐, 来估计这个 distribution 到底是什么样的一个 distribution.

这里这些统计量, 由于是以 Borel measurable 的方式组合起多个 random variables, 也是 random variables. 所以这个 proposition 其实也奠定了统计学中各种统计量的合法性.

2.1.2 由一个 random variable generate 的 σ -algebra

Def 2.2 (σ -algebra generated by a random variable (measurable function))

对于 random variable $X : \Omega \rightarrow \mathbb{R}$, 其 generate 的 σ -algebra 定义为

$$\sigma(X) := \{X^{-1}(B) : B \in \mathcal{B}(\mathbb{R})\} \subseteq \mathcal{F}$$



这个集合 $\sigma(X)$ 是一个 σ -algebra, 是一个 trivial truth. 因为里面所有的 set 都是 X 的 preimage, 而 X 是一个 measurable function, 因而任意的 $X^{-1}(B) \in \mathcal{F}$.

这个 $\sigma(X)$ 也是让 X 成为一个 measurable function (即 random variable) 的最小的 σ -algebra. 它的意义是: 当我们仅仅观察到 X 的取值时, 我们所掌握的关于 underlying sample space Ω 的全部 "information".

Remark 我们知道, 一个 σ -algebra $\mathcal{F}$ 可以看作是一个 information structure: 它是对 underlying sample

space Ω 进行划分的一个工具.

最大的 σ -algebra $\mathcal{P}(\Omega)$, 即 power set, 是最细的划分, 也是信息量最大的 σ -algebra. 它把每一个元素都区分开来. 对于 discrete 的 sample space, 通常我们的 probability measure 就是定义在 power set 上的, 正是因为我们希望区分每一个 outcome.

而给定一个 prob space $(\Omega, \mathcal{F}, \mathbb{P})$, 原本的 prob measure 所 base on 的 σ -algebra $\mathcal{F}$ 就成为了一个基准的 information 的颗粒度: 哪些事件是我们可以区分, 即可以在上面定义 probability 的.

而一个 random variable X 可能会把多个 outcomes 映射到同一个值上, 也即把多个 events 映射到同一个值上, 从而把这些 events 区分不开来. 因而, **random variable X generate 的 σ -algebra $\sigma(X)$ 就可能是一个更粗的划分**. 当我们取这些 events 所映射到的同一个值的 preimage 的时候, 取到的是它们的 union, 也就是它们中最大的一个.

比如

Example 2.2 掷一次骰子, 所有可能结果为 sample space:

$$\Omega = \{1, 2, 3, 4, 5, 6\}$$

而我们定义一个 random variable X 来表示掷出的点数的奇偶性, 即:

$$X(\omega) = \begin{cases} 1, & \omega \in \{2, 4, 6\} \\ 0, & \omega \in \{1, 3, 5\} \end{cases}$$

那么它 generate 的 σ -algebra:

$$\sigma(X) = \{\emptyset, \{1, 3, 5\}, \{2, 4, 6\}, \Omega\}$$

因为 1, 3, 5 这些事件都被映射到了同一个值 0 上, 即 $\{1\}, \{3\}, \{5\}, \{1, 3\}$ 这些事件都被 $\{1, 3, 5\}$ 这个事件吸收了, 它们在这个 random variable X 的映射下是区分不开的. 这就代表了这个 random variable 所蕴含的信息颗粒度: **我们只能区分掷出的点数是奇数还是偶数, 但是无法区分具体的点数是多少**.

至此我们知道: 一个 random variable X 的 generate 的 σ -algebra $\sigma(X)$ 表示了这个 random variable 对 **underlying sample space Ω 所能区分的 information granularity (信息颗粒度)**.

除了能表示 information granularity 以外, $\sigma(X)$ 还有什么实际用处呢:

- 之后讨论关于 independence of two random variables X 和 Y 时, 可以用它来作严格定义, 并且展现 independence 的本质: 两个 RV 的 independence 实际表示它们蕴含的信息颗粒度之间没有任何 overlap
- 用以定义 conditional expectation: $\mathbb{E}[Y|\sigma(X)]$, 通常简写为 $\mathbb{E}[Y|X]$, 但是其实 $\mathbb{E}[Y|\sigma(X)]$ 是一个更加直观的事情, 表述了一种 Partial Averaging 的概念.
- Stochastic Process 中有众多应用. 比如 stopping time 的定义.

至此关于 random variable, 我们已经讨论了很多 general 的刻画. 现在我们来讲一点实用的:

2.2 distributions

2.2.1 distribution and cumulative distribution function

Def 2.3 (probability distribution)

对于 random variable $X : \Omega \rightarrow \mathbb{R}$ on $\Omega, \mathcal{F}, \mathbb{P}$, 其 probability distribution 是 X 对于 $\mathbb{P}$ 的 pushforward measure, 记作 $\mathbb{P}^X : \mathcal{B}(\mathbb{R}) \rightarrow [0, 1]$. 即

$$\mathbb{P}^X(B) := \mathbb{P}(X^{-1}(B)), \quad \forall B \in \mathcal{B}(\mathbb{R})$$

我们 write:

$$X \sim \mathbb{P}^X$$



Remark 看着有点不直观. 实则我们拆解:

- $X^{-1}(B)$ 即: 有多少 samples (即哪一个事件 $E \in \mathcal{F}$) 在这个 RV X 的映射下落入 B 这个区间?
- $\mathbb{P}(X^{-1}(B))$ 即: 这个事件 E 的概率是多少?

接下来的定义和例子会更加直观.

Def 2.4 (distribution function (也称 cumulative distribution function, cdf))

对于 random variable $X : \Omega \rightarrow \mathbb{R}$, 其 **cumulative distribution function** 是 $\mathbb{P}^X$ 这一函数的 distribution function, 记作 F_X . 即对于任意 $x \in \mathbb{R}$, 有

$$F_X(x) := \mathbb{P}^X((-\infty, x]) = \mathbb{P}(X^{-1}((-\infty, x]))$$



Remark $F_X(x)$ 即 $\mathbb{P}(\{X \leq x\})$ 我们也会简写为 $\mathbb{P}(X \leq x)$.

$F_X(x)$ 的意义是: random variable X 的值不超过 x 的概率.

Example 2.3 (geometric probability) Fix $a, b > 0$. 我们在正方形区域 $\Omega = [0, a] \times [0, b]$ 上均匀地随机选取一个点 (x, y) .

我们 define 随机变量: $X : \Omega \rightarrow \mathbb{R}$ by $X(x, y) = x$. 求 X 的 distribution function F_X .

这很简单: 对于 $x \in [0, a]$,

$$F_X(x) = \mathbb{P}(X \leq x) = \frac{m([0, x] \times [0, b])}{m([0, a] \times [0, b])} = \frac{x \cdot b}{a \cdot b} = \frac{x}{a}, \quad 0 \leq x \leq a$$

因为

$$F_X(x) = \begin{cases} 0, & x < 0 \\ \frac{x}{a}, & 0 \leq x \leq a \\ 1, & x > a \end{cases} \quad (2.1)$$

注意: 在这个例子中, probability measure P 是 Lebesgue measure on $[0, a] \times [0, b]$. 很多时候我们在计算 RV 的 distribution function 的时候, 都是直接直观地计算 $\mathbb{P}(X \leq x)$. 但是在稍微复杂一些的例子中, 我们需要对各个条件的 formalization 更清楚一点.

Theorem 2.1 (distribution function 的性质)

对于 random variable $X : \Omega \rightarrow \mathbb{R}$, 其 distribution function F_X 满足:

- F_X 是 non-decreasing (non-strictly increasing) 的.
- $\lim_{x \rightarrow +\infty} F_X(x) = 1, \lim_{x \rightarrow -\infty} F_X(x) = 0$.
- F_X 是 right-continuous 的. 即对于任意 x_0 , 有 $\lim_{x \rightarrow x_0^+} F_X(x) = F_X(x_0)$.
- 对于任意 x_0 , 有 $\lim_{x \rightarrow x_0^-} F_X(x) = P(X < x_0)$. 并且 $\mathbb{P}(X = x_0) = \lim_{x \rightarrow x_0^+} F_X(x) - \lim_{x \rightarrow x_0^-} F_X(x)$.
- 对于任意 $x_1 < x_2$, 有 $P(X \in (x_1, x_2]) = F_X(x_2) - F_X(x_1)$.



Proof 其他都显然. right-continuity 是源自 measure 的 continuity from above, 我们证明一下: 考虑一个单调递减序列 $\{x_n\} \downarrow x_0$, 令 seq of events $A_n = \{X \leq x_n\}$, 注意这是一个嵌套递减的 set seq. 通过 $\mathbb{R}$ 的 completeness 容易证明:

$$A_0 = \bigcap_{n=1}^{\infty} A_n = \{\omega : X(\omega) \leq x_0\}$$

由 measure 的 continuity from above, $\mathbb{P}(A_0) = \lim_{n \rightarrow \infty} \mathbb{P}(A_n)$. 也即 $\lim_{x \rightarrow x_0^+} F_X(x) = \mathbb{P}(X \leq x_0)$.

而下面一条 $\lim_{x \rightarrow x_0^-} F_X(x) = \mathbb{P}(X < x_0)$ 同理是源自 measure 的 continuity from below.

那么 $\mathbb{P}(X = x_0) = \mathbb{P}(X \leq x_0) - \mathbb{P}(X < x_0)$ 是 natural 的 (by def). □

Remark 我们此时心里会默认一件事情: 一旦知道了 RV X 的 distribution function F_X , 就知道了 X 的完整 distribution P^X . 这个直觉是对的.

回忆一下: 我们在 measure theory 中, 证明 Carathéodory extension theorem 的时候, 证明过一个 $\pi - \lambda$ theorem, 以它作为工具才把 premeasure 从一个 algebra extend 到一个 measure on the generated σ -algebra:

Theorem 2.2 (Dynkin's $\pi - \lambda$ theorem)

设 $\mathcal{P}$ 是一个 π -system (closed under finite intersection), $\mathcal{L}$ 是一个 λ -system (closed under complementation and countable disjoint union), 如果 $\mathcal{P} \subseteq \mathcal{L}$, 那么 $\sigma(\mathcal{P}) \subseteq \mathcal{L}$.



我们考虑所有的 half-open interval $(-\infty, x]$ 组成的集合 $\mathcal{G}$, 这个集合 generate the Borel σ -algebra, 并且还是一个 π -system, 即: 它 closed under finite intersection:

$$(-\infty, a] \cap (-\infty, b] \in \mathcal{G}, \quad \forall a, b \in \mathbb{R}$$

然后考虑

$$\mathcal{L} := \{E \in \sigma(\mathcal{G}) : \mathbb{P}_1(E) = \mathbb{P}_2(E)\}$$

即两个 measure 一致的 collection of sets. 容易证明, 这个 $\mathcal{L}$ 是一个 λ -system, 并且 $\mathcal{G} \subset \mathcal{L}$.

从而,

$$\mathbb{B}(\mathbb{R}) = \sigma(\mathcal{G}) \subseteq \mathcal{L}$$

并且 $\mathbb{P}_1(E) = \mathbb{P}_2(E)$ 对于任意 $E \in \mathbb{B}(\mathbb{R})$.

因而:

Corollary 2.1 (distribution function F_X determines distribution $\mathbb{P}^X$)

对于 random variable $X : \Omega \rightarrow \mathbb{R}$, 其 distribution function F_X 确定了 distribution $\mathbb{P}^X$; 即如果两个 random variable X 和 Y 满足 $F_X = F_Y$, 那么 $\mathbb{P}^X = \mathbb{P}^Y$.

**2.2.2 discrete random variable 与 probability mass function**

我们基本上研究两类 random variable: discrete random variable 和 continuous random variable.

Def 2.5 (discrete random variable)

对于 random variable $X : \Omega \rightarrow \mathbb{R}$, 如果存在一个 countable set $S \subseteq \mathbb{R}$ 使得 $\mathbb{P}(X \in S) = 1$, 那么 X 是一个 discrete random variable.



Remark 就是说, X 的 range a.s. 是 countable 的 (允许 null set 上的值不在这个 countable set 里, 但是这是 measure theory 下的概念, 所以这些都可以忽略不计).

Remark 对于 discrete random variable X , 其 distribution function F_X 是一个 step function, 只有 countable 多个 jump discontinuity, 每个 jump 的大小就是 X 在那个点的 probability mass.

因而, 对于 discrete random variable X , 通常考虑其 **probability mass function (pmf)** p_X 更加有用:

Def 2.6 (probability mass function (pmf))

对于 discrete random variable X , 其 pmf 定义为

$$p_X(x) := \mathbb{P}(X = x), \quad \forall x \in \mathbb{R}$$



这个 pmf 就是 F_X 的 jump size function. 当然, 根据定义明显可得:

$$\sum_x p_X(x) = 1$$

值得一提的是, 这个 pmf 其实就是 X 的 distribution $\mathbb{P}^X$ 对于 counting measure (for range of X) 的 Radon-Nikodym derivative:

Proposition 2.2 (pmf 是 distribution 对于 counting measure μ_S 的 Radon-Nikodym 导数)

对于一个 discrete random variable X , 假设其 range 是 countable set S , 则我们定义 counting measure μ_S on S 为:

$$\mu_S(A) := \sum_{x_i \in S} \mathbf{1}_A(x_i)$$

那么, distribution $\mathbb{P}^X \ll \mu_S$ (绝对连续), 并且有:

$$p_X = \frac{d\mathbb{P}^X}{d\mu_S}$$



Proof 这很容易证明. 首先, 这个 counting measure 即: A 中有多少个点在 S 中.

那么显然, 如果 $\mu_S(A) = 0$, 即 A 中没有点在 S 中, 那么 $\mathbb{P}^X(A) = 0$. 因而 $\mathbb{P}^X \ll \mu_S$.

且对于任意 Borel set A ,

$$\mathbb{P}^X(A) = \sum_{x_i \in A} \mathbb{P}(X = x_i) = \sum_{x_i \in A \cap S} p_X(x_i) = \int_A p_X(x) d\mu_S(x)$$

□

2.2.3 continuous random variable 与 probability density function

相对应 discrete random variable, 我们定义 continuous random variable:

Def 2.7 (continuous random variable)

我们称一个 random variable $X : \Omega \rightarrow \mathbb{R}$ 是一个 **continuous random variable**, 如果它的 cdf F_X 是一个 **absolutely continuous function**.



Remark 回顾 absolutely continuous function 的定义, 这是一个比较复杂的定义: 对于任意 $\epsilon > 0$, 都存在 $\delta > 0$ 使得任取 finite collection of disjoint intervals $\{(a_i, b_i)\}$, 都满足:

$$\sum_i (b_i - a_i) < \delta \implies \sum_i |F_X(b_i) - F_X(a_i)| < \epsilon$$

这是 uniform continuity 的一个加强版本. uniform continuity 对应的是 $n = 1$ 的情况, 即: 任意的区间上, 只要长度足够小, 就能保证 F_X 在这个区间上的增量足够小; 而 absolutely continuity 更严格: 即便是任意数量的分散的区间, 只要总长度足够小, 就能保证 F_X 在这些 interval 上的增量的总和足够小.

这个定义有点麻烦, 不过存在等价的条件. 为此我们要 recall 一系列定义与结论, 详情请见: [notes on measure theory, module 12: differentiation on \$\mathbb{R}\$](#) :

- 给定一个 function $F : \mathbb{R} \rightarrow \mathbb{C}$, 我们定义它的 **total variation function** $V_F : \mathbb{R} \rightarrow [0, +\infty]$ 为:

$$T_F(x) := \sup \left\{ \sum_{i=1}^n |F(x_i) - F(x_{i-1})| \mid -\infty < x_0 < \dots < x_n \right\}$$

- 如果 $T_F(\infty) < \infty$ (注意这是单调递增函数, 因而即对于任意的 x 都有 $T_F(x) < \infty$), 那么我们称 F 是一个 **function of bounded variation**, 写作 $F \in BV$.
- 如果 $F \in BV$, 且 F 是 right-continuous 的, 且 $F(-\infty) = 0$, 那么我们称 $F \in NBV$. (即 normalized function of bounded variation).
- 任意的 $F \in NBV$ 都 **m-a.e. differentiable**, 且导数 $F' \in L^1(m)$, 并且以下三个条件等价:

$$F \in AC \tag{2.2}$$

$$\iff \mu_F \ll m \tag{2.3}$$

$$\iff F(x) = \int_{-\infty}^x F'(t) dt \quad \forall x \in \mathbb{R} \tag{2.4}$$

这几行字浓缩了 measure theory 的 differentiation theory 的两个星期的内容... 具体见上文 notes 链接, 都有详细证明. 而我们这里就利用起最后这一条结论. 首先, 我们 state 一件事:

Lemma 2.1 (cdf 一定是 NBV 的)

任意的 random variable 的 cdf F_X 都是一个 NBV function.



Proof 依旧见 notes, 有一个关键 lemma: $F \in BV$ 当且仅当它可以表示为两个 monotone increasing function 的差. 而 random variable 的 cdf F_X 自身是一个 non-decreasing function, 因而首先 $F_X \in BV$.

其次, 由 2.1 我们知道, F_X 是 right-continuous 的, 且 $F_X(-\infty) = 0$. 因而 $F_X \in NBV$. $\square$

因而我们自然得出:

Theorem 2.3 (一个 random variable 是 continuous random variable 的充要条件)

- 一个 random variable $X : \Omega \rightarrow \mathbb{R}$ 的 cdf 一定是 m -a.e. differentiable 的.
- X 是一个 continuous random variable 当且仅当 $\mathbb{P}^X \ll m$, 即当且仅当存在一个函数 $f_X : \mathbb{R} \rightarrow [0, \infty)$, 使得对于任意 Borel set $A \subseteq \mathbb{R}$, 有

$$\mathbb{P}^X(A) = \int_A f_X dm$$

这个函数 f_X 即是:

- **distribution 对于 Lebesgue measure 的 Radon-Nikodym derivative:** $f_X = \frac{d\mathbb{P}^X}{dm}$.
- **cdf F_X 的 m -a.e. 导数 $f_X = F'_X$.**

我们也称这个 f_X 是 continuous random variable X 的 **probability density function (pdf)**. 

Proof 即 remark 的最后一条结论. 由于 F_X 是一个 NBV function, 因而 F_X 是 m -a.e. differentiable 的. 并且, $F_X \in AC$ iff 它满足 FTC of Lebesgue integral. $\square$

Remark 因而, 在简化的教材中, 通常会直接定义: 一个 random variable X 是 continuous random variable, 如果存在一个 f_X 使得 $F_X(x) = \int_{-\infty}^x f(t) dt$ for all x . 这里其实是跳过了我们刚才的所有步骤, 直接使用了这个等价条件. 因为这个条件也等价于:

$$F_X(x) = \int_{-\infty}^x F'_X(t) dt \quad \forall x \in \mathbb{R}$$

Def 2.8 (probability density function (pdf))

对于 continuous random variable X , 其 probability density function 定义为 F_X 的 (m -a.e.) 导数, 即

$$f_X(x) := F'_X(x), \quad m\text{-a.e. } x \in \mathbb{R}$$


我们最后梳理一下.

- 任意的 random variable 的 cdf F_X 都是一个 NBV function, 因而一定 a.e. 可导. 但是它的导数 F'_X 的积分不一定返回原函数.
- 如果一个 m -a.e. 导数 F'_X 满足 $F_X(x) = \int_{-\infty}^x F'_X(t) dt$ 对所有 $x \in \mathbb{R}$ 成立, 即导数的积分返回原函数, 那么 X 就是一个 continuous random variable, 而我们定义 $f_X := F'_X$ 为 X 的 probability density function.

以及, 显然 pdf 有以下性质:

Proposition 2.3 (probability density function 的性质)

对于 continuous random variable X with pdf f_X ,

- $f_X(x) \geq 0$ for m -a.e. $x \in \mathbb{R}$. (因为 F_X 是 non-decreasing 的.)
- $\int_{-\infty}^{+\infty} f_X(x) dx = 1$. (因为 $F_X(\infty) = 1$.)
- 对于任意 Borel set A , 有

$$\mathbb{P}(X \in A) = \mathbb{P}^X(A) = \int_A f_X(x) dx$$

- 对于 m -a.e. $x \in \mathbb{R}$,

$$f_X(x) = \lim_{\epsilon \rightarrow 0^+} \frac{\mathbb{P}^X([x, x + \epsilon))}{\epsilon} = \lim_{\epsilon \rightarrow 0^+} \frac{F_X(x + \epsilon) - F_X(x)}{\epsilon}$$


2.2.4 singular continuous random variable 与 Lebesgue Decomposition Theorem

对于 continuous random variable 的定义, 有些地方会简化定义为: continuous random variable 就是指其 cdf 是一个 continuous function.

但是我们现在知道, 这个定义是错的. 首先, 标准定义中的 absolutely continuous 要强于 continuous (它能推导出 a.e. differentiable); 而且, **这个更强的定义是 necessary 的.**

因为当提及 continuous random variable 时, 通常意思是它存在一个 pdf. 而存在一个 pdf 即意味着它满足 FTC of Lebesgue integral, 也就等价于 F_X 一定是一个 absolutely continuous function. 而仅仅 continuous 什么都无法保证.

我们这里给出一个 counterexample: Cantor distribution. 它的 cdf 是 continuous 的, 但是它并没有能够满足 FTC of Lebesgue integral (返回原函数) 的 a.e. derivative, 因而没有 pdf.

Example 2.4 (Cantor distribution)

令 X_n be 独立同分布 (i.i.d.) 的随机变量 $P(X_n = 0) = P(X_n = 2) = 1/2$. 然后定义:

$$X := \sum_{n=1}^{\infty} \frac{X_n}{3^n}$$

它刻画的是:

- 把 $[0, 1]$ 三等分, 去掉中间的部分, 然后在剩下的两部分中, 以 $1/2$ 的概率选择左边的区间, 以 $1/2$ 的概率选择右边的区间;
- 在选定的区间中, 再把它三等分, infinitely 重复这一过程.
- 最后, 这一行为会收敛于 Cantor set 上的一个点.

具体而言:

- 第 1 步 ($n = 1$) 我们查看 $\frac{X}{3^1}$, 如果 $X_1 = 0$, 你选择了左边的区间 $[0, 1/3]$; 如果 $X_1 = 2$, 你选择了右边的区间 $[2/3, 1]$.
- 第 2 步 ($n = 2$): 在第 1 步选定的区间内, 查看 $\frac{X}{3^2} = \frac{X_2}{9}$ 如果 $X_2 = 0$, 你在当前小区间内选择了左侧的 $1/3$; 如果 $X_2 = 2$, 你在当前小区间内选择了右侧的 $1/3$.
- ...

从而, X 的 range 是 Cantor set, recall: 这是一个 measure zero 的 uncountable set, 其 cardinality 是 continuum (与 $\mathbb{R}$ 等势).

$$C = \{x \in [0, 1] \mid x = (0.a_1a_2a_3\dots)_3, \text{ where } a_i \in \{0, 2\}\}$$

它也表示了: 三进制小数中, 所有完全不包含数字 1 的小数的集合.

由于其 uncountability, 对于任意单点 x 都有 $\mathbb{P}(X = x) = 0$, 因而 F_X 在 $\mathbb{R}$ 上处处连续; 并且容易证明: F_X 在 x 处的导数 $F'_X(x) = 0$. (因为对于 C^c 中的任意被挖掉的区间, F_X 在这个区间上是 constant 的). 然而, $F'_X = 0$ 却不满足 FTC of Lebesgue integral. 比如反例: $F_X(1) = 1$, 但是

$$\int_{-\infty}^1 F'_X(t) dt = 0$$

因而 X 没有 pdf, 也就不是 continuous random variable.

对于 Cantor distribution 这个例子, 我们称这样的 random variable 是一个 **singular continuous random variable**:

Def 2.9 (singular continuous random variable)

对于 random variable $X : \Omega \rightarrow \mathbb{R}$, 如果 X 的 cdf F_X 是一个 continuous function, 并且 $\mathbb{P}^X \perp m$ (即存在一个 measure zero 的 Borel set N 使得 $\mathbb{P}^X(N) = 1$, 也等价于 F_X 的导数 $F'_X = 0$ a.e.), 那么我们称 X 是一个 singular continuous random variable.



Remark singular continuous random variable 的意思是, 在 $\mathbb{R}$ 上, X 的值 a.s. 落在一个 measure zero 的 set 上, 也就是说它的 cdf 大部分是平的, 只有在 measure zero 的 set 上才有 jump.

这个例子向我们说明了: 除了 discrete random variable 和 continuous random variable 以外, 还有其他的奇异的 random variables. 而下面这一定理刻画了任意的 random variable 的结构:

Theorem 2.4 (Lebesgue Decomposition Theorem)

对于任意 random variable $X : \Omega \rightarrow \mathbb{R}$, 其 distribution $\mathbb{P}^X$ 可以唯一分解为三个 mutually singular 的 measure 的和:

$$\mathbb{P}^X = \mathbb{P}_{ac}^X + \mathbb{P}_{sc}^X + \mathbb{P}_d^X$$

其中 $\mathbb{P}_{ac}^X \ll m$ 是 absolutely continuous measure, $\mathbb{P}_{sc}^X \perp m$ 是一个 singular continuous measure, $\mathbb{P}_d^X \perp m$ 是 discrete measure.



Proof TODO. □

Remark 我们也可以这样展开:

$$F_X(x) = \int_{-\infty}^x f_{ac}(t) dt + \sum_{x_i \leq x} p_d(x_i) + F_{sc}(x)$$

其中 f_{ac} 是 X_{ac} 的 pdf, p_d 是 X_d 的 pmf, 而 F_{sc} 由于其奇异性是无法分解的.

2.3 expectation and variance

Distribution 是一个 random variable 的完整刻画, 而这一节我们来谈一谈 expectation 和 variance, 这是一个 random variable 的两个重要的数值特征: 它的均值和离散程度.

最后我们会谈一谈 $L^2(\Omega, \mathcal{F}, \mathbb{P})$ 空间: all square-integrable random variables; 以及它的一个重要 subspace $L_0^2(\Omega, \mathcal{F}, \mathbb{P})$: 所有 square-integrable 的 zero-centered random variables. 它们都是由 random variables 组成的 Hilbert space, 并且在其中, expectation, variance, covariance 都会得到一个非常自然的 interpretation, 展现这个空间的几何结构.

2.3.1 expectation and variance 的 definition 和计算方法

随机变量的 **expectation** 是它 w.r.t. 它所在概率空间 prob measure $\mathbb{P}$ 的积分, 表示它的值的 prob-weighted average;

而其 **variance** 是 $(X - E(X))^2$ 这个 induced RV w.r.t. $\mathbb{P}$ 的积分, 表示 X 离它的值的 weighted average $E(X)$ 的聚集程度:

Def 2.10 (expectation and variance of random variable)

对于 random variable $X : \Omega \rightarrow \mathbb{R}$, 其 expectation 定义为

$$\mathbb{E}[X] := \int_{\Omega} X \, d\mathbb{P}$$

其 variance 定义为

$$\text{Var}(X) := \mathbb{E}[(X - \mathbb{E}[X])^2] = \int_{\Omega} (X - \mathbb{E}[X])^2 \, d\mathbb{P}$$



Remark $\int_{\Omega} d\mathbb{P} = \mathbb{P}(\Omega) = 1$, 因而 $\mathbb{E}[X]$ 可以看作是 X 的值的 weighted average, 其中权重就是每个 sample point 在这个原 prob space 上的概率.

Note that: $\mathbb{E}[X]$ 未必是 finite 的. $\mathbb{E}[X] < \infty \iff X \in L^1(\mathbb{P})$. $\text{Var}(X) < \infty \iff X \in L^2(\mathbb{P})$

要计算 discrete random variable 的 expectation 和 variance, 直接 by def, sum 就可以:

Proposition 2.4 (discrete random variable 的 expectation 和 variance)

对于 discrete random variable X with pmf p_X ,

$$\mathbb{E}[X] = \sum_x x p_X(x), \quad \text{Var}(X) = \sum_x (x - \mathbb{E}[X])^2 p_X(x)$$



非常简单.

但是对于 continuous random variable 而言, 怎么求呢? 这里有一个 w.r.t. prob measure $\mathbb{P}$ 的积分, 有点难计算. 我们更希望计算 w.r.t. Lebesgue measure m 的积分, 这样就可以用一些经典的方法来算它了.

为了实现这个目标, 我们首先需要有一个工具来过渡一下:

Lemma 2.2 (用 distribution (X 的 push-forward measure) 计算 expectation)

对于 random variable $X : \Omega \rightarrow \mathbb{R}$, 如果 X integrable, 那么其 expectation

$$\mathbb{E}[X] = \int_{\mathbb{R}} x \, d\mathbb{P}^X(x)$$



Proof 这个结论是 Lebesgue integral 的 change of variable formula 的一个 special case. 注意, $X = \text{id} \circ X$ ($\text{id} : \mathbb{R} \rightarrow \mathbb{R}$ 是恒等函数).

By change of variable formula,

$$\int_{\Omega} X \, d\mathbb{P} = \int_{\Omega} (\text{id} \circ X) \, d\mathbb{P} = \int_{\mathbb{R}} \text{id}(x) \, d\mathbb{P}^X(x) = \int_{\mathbb{R}} x \, d\mathbb{P}^X(x)$$

(如果不用 change of variable theorem, 也可以证明. 考虑 simple function 的 case, 显然; 然后对 simple function 自然成立, 然后用 monotone convergence theorem 推广到一般情况.)

//TODO: 从 diffeomorphism version 的 change of variable formula 证明 push-forward version 的 change of variable formula, 然后 apply 这个结论. 参考: [change of variable](#) □

Proposition 2.5 (continuous random variable 的 expectation 和 variance)

对于 continuous random variable X with pdf f_X , 如果 $\mathbb{E}[X]$ 和 $\text{Var}(X)$ 都是 finite 的, 那么

$$\mathbb{E}[X] = \int_{-\infty}^{+\infty} x f_X(x) \, dx, \quad \text{Var}(X) = \int_{-\infty}^{+\infty} (x - \mathbb{E}[X])^2 f_X(x) \, dx$$

并且, 对于任意的 measurable function $g : \mathbb{R} \rightarrow \mathbb{R}$, 都有

$$\mathbb{E}[g(X)] = \int_{-\infty}^{+\infty} g(x) f_X(x) dx$$



Proof 由于 $\mathbb{E}[X] = \int_{\mathbb{R}} x d\mathbb{P}^X(x)$, 而对于 ctn random variable,

$$d\mathbb{P}^X(x) = f_X(x) d\lambda(x)$$

从而得证. □

Proposition 2.6 (expectation 的性质)

令 $X, Y : \Omega \rightarrow \mathbb{R}$ 为 **integrable** random variables, 则

- **linearity of expectation:** $\mathbb{E}[aX + bY] = a\mathbb{E}[X] + b\mathbb{E}[Y]$ for any $a, b \in \mathbb{R}$.
- **monotonicity of expectation:** 如果 $X \leq Y$ a.s., 那么 $\mathbb{E}[X] \leq \mathbb{E}[Y]$.
- **absolute value:** $\mathbb{E}[X] \leq \mathbb{E}[|X|]$



这三条性质都容易验证, 直接 follow from linearity of Lebesgue integral, monotonicity of Lebesgue integral, triangle inequality of Lebesgue integral.

Proposition 2.7 (computing variance)

对于 random variable X with finite expectation,

$$\text{Var}(X) = \mathbb{E}[X^2] - (\mathbb{E}[X])^2$$



By def, 容易验证.

2.3.2 $L^2_0(\Omega, \mathcal{F}, \mathbb{P})$ 与 covariance and correlation as inner product and cosine

我们 recall measure theory 中的一丢丢 functional analysis 的内容:

$$L^2(\Omega, \mathcal{F}, \mathbb{P}) = \{X : \Omega \rightarrow \mathbb{R} \mid X \text{ is measurable (即 RV) and } \mathbb{E}[X^2] < \infty\} / \sim$$

where $\sim$ 表示 almost sure equality 的等价类, 即

$$X \sim Y \iff \mathbb{P}(\{\omega \in \Omega : X(\omega) = Y(\omega)\}) = 1$$

即把所有 a.s. 相等的 random variables 都看作相等.

我们知道, 这是一个 **Hilbert space**, 即一个 complete inner product space, 其中

- 两个 random variables as vectors 的 inner product 定义为: $\langle X, Y \rangle := \mathbb{E}[XY]$ 即它们的 second
- 一个 random variable 的 norm 即: $\|X\| := \sqrt{\langle X, X \rangle} = \sqrt{\mathbb{E}[X^2]}$ 即它的 second moment 的 square root. 它表示了这个 random variable 的整体离散程度.

虽然这个空间已经有一定的 information geometry 了, 但是我们实际上希望能够用一个结构来描述两个 random variables 之间的线性相关性:

- 任意取一个 ω , $X(\omega)$ 较大 (距离它的 expectation 较远) 的时候, $Y(\omega)$ 是否也通常较大 (距离它的 expectation 较远)? $X(\omega)$ 较小的时候, $Y(\omega)$ 是否也通常较小?

而 $L^2(\Omega, \mathcal{F}, \mathbb{P})$ 这个空间作为一个 Hilbert space 时, 两个 random variables 之间的距离其实是它们作为函数的相似性而不是它们变化趋势 (波动) 的相似性.

比如考虑 $X = x$ 和 $Y = x+5$, 它们的线性相关性其实是 1, 即变化趋势完全相同, 但是它们在 $L^2([0, 4], \mathcal{F}, \mathbb{P})$ 中的 cosine similarity 却是

$$\frac{\langle X, Y \rangle}{\|X\| \|Y\|} = \frac{46/3}{\sqrt{(16/3)(151/3)}} = \frac{46}{\sqrt{2416}} \approx 0.936$$

我们希望的是这个 cosine similarity 应当是 1. 即, 应该忽略掉绝对数值, 而是考虑这两个 random variables 的变化趋势.

因而 solution: normalize 每个 random variable, 把它们移动到均值为 0 的位置! 即: 把每个 X center 为 $X - \mathbb{E}[X]$. 这就是:

Def 2.11 (zero-centered square integrable random variables $L_0^2(\Omega, \mathcal{F}, \mathbb{P})$)

我们定义:

$$L_0^2(\Omega, \mathcal{F}, \mathbb{P}) := \{X \in L^2(\Omega, \mathcal{F}, \mathbb{P}) \mid \mathbb{E}[X] = 0\}$$

注意, 这个空间是 $L^2(\Omega, \mathcal{F}, \mathbb{P})$ 的一个 subspace.



并且, 我们可以通过把每个 X center 为 $X - \mathbb{E}[X]$ 的行为, 把 X 从 $L^2(\Omega, \mathcal{F}, \mathbb{P})$ 投影到 $L_0^2(\Omega, \mathcal{F}, \mathbb{P})$ 这个 subspace 上.

而投影+度量的行为, 就是计算:

Def 2.12 (covariance)


给定两个 random variables X, Y , 我们定义它们的 covariance 为

$$\text{Cov}(X, Y) := \mathbb{E}[(X - \mathbb{E}[X])(Y - \mathbb{E}[Y])] = \mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y]$$




Remark Geometric intuition of covariance: 考虑取这两个 random variables 的一些 sample points 并分别作为 (x, y) 坐标.

- 如果它们的 covariance 是正的, 那么这些 sample points 倾向于拟合为一个斜率为正的 tendency line;
- 如果它们的 covariance 是负的, 那么这些 sample points 倾向于拟合为一个斜率为负的 tendency line;
- 如果它们的 covariance 是 0, 那么这些 sample points 倾向于拟合为一个水平的 tendency line.



但是注意:

- covariance 只捕捉 linear relationship, 即趋势是否呈直线, 不过不能捕捉 nonlinear relationship. 之后在学习 independence 的时候, 我们会知道即便 covariance 为 0, X 和 Y 仍然可能是 dependent 的. 比如, 如果 (X, Y) 的联合分布 as a graph 是个圆圈, 那么 covariance 就是 0, 但显然这两个变量之间是有关系的.



$\text{Cov}(X, Y) = 0$, but X, Y are not independent

- Covariance 的数值还包括了这两个 random variables 的 scale, 因而还不能直接用来比较不同 random variables 之间的 linear relationship 的强弱程度. 真正公平的 linear relationship 还需要 normalize by norms, 把这个关系定位到 $[-1, 1]$ 的区间上 即等下定义的 correlation.

我们容易发现一件事情:

Theorem 2.5 (covariance 是一个 a positive semi-definite symmetric bilinear form)

- covariance 是一个 **symmetric bilinear form** (并且 **translation-invariant**, 忽略 translation) 的 operator:

$$\text{Cov}(aX + b, cY + d) = ac \text{Cov}(X, Y)$$

$$\text{Cov}(X, Y) = \text{Cov}(Y, X)$$

$$\text{Cov}(X + Y, Z) = \text{Cov}(X, Z) + \text{Cov}(Y, Z)$$

- covariance 满足 positive definiteness: $\text{Cov}(X, X) = \text{Var}(X) \geq 0$.



Proof By def. □

而当我们把空间限定在 $L_0^2(\Omega, \mathcal{F}, \mathbb{P})$ 上时,

Theorem 2.6 ($L_0^2(\Omega, \mathcal{F}, \mathbb{P})$ 为一个 Hilbert space, with covariance as an inner product)

$(L_0^2(\Omega, \mathcal{F}, \mathbb{P}), \langle \cdot, \cdot \rangle_{\text{Cov}})$ 为一个 Hilbert space, 即: covariance 在其上是一个 inner product (positive definite symmetric bilinear form).



Proof 很显然. 因为在 L^2 space 上, 一个 constant random variable 的 variance 是 0, 但是它并不是一个零函数; 而在 L_0^2 space 上, 所有的 random variables 都是 zero-centered 的, 因而 constant random variable 就是零函数了. 从而 covariance 在 L_0^2 space 上是 positive definite 的, 从而是 inner product.

□

而在 $L_0^2(\Omega, \mathcal{F}, \mathbb{P})$ 上, 两个 random variables X, Y 之间的夹角 θ 的 cosine, 就是它们真正的 linear relationship 的强弱程度, 因而我们把它叫做 correlation:

Def 2.13 (correlation)

$$\rho(X, Y) = \frac{\text{Cov}(X, Y)}{\sqrt{\text{Var}(X)}\sqrt{\text{Var}(Y)}}$$



显然,

$$\rho(X, Y) = \cos \theta$$

where θ 是 X, Y 之间的夹角. And we have:

$$\text{Cov}(X, Y) = \sigma_X \sigma_Y \rho(X, Y)$$

从而有以下显然的结论:

Proposition 2.8 (properties of correlation)

- $\rho(X, Y) \in [-1, 1]$
- 如果 $\rho(X, Y) = 1$, 那么 $Y = aX + b$ for some $a > 0$ and b ; 如果 $\rho(X, Y) = -1$, 那么 $Y = aX + b$ for some $a < 0$ and b .
- By Cauchy-Schwarz inequality, $|\text{Cov}(X, Y)| \leq \sigma_X \sigma_Y$.



做一个总结:

	L^2 space	L_0^2
inner product $\langle X, Y \rangle$	$\mathbb{E}[XY]$	$\text{Cov}(X, Y)$ (covariance)
norm $\ X\ $	$\sqrt{\mathbb{E}[X^2]}$	$\sqrt{\text{Var}(X)}$ (standard deviation)
cosine similarity	$\frac{\mathbb{E}[XY]}{\sqrt{\mathbb{E}[X^2]}\sqrt{\mathbb{E}[Y^2]}}$	$\frac{\text{Cov}(X, Y)}{\sqrt{\text{Var}(X)}\sqrt{\text{Var}(Y)}}$ (correlation)

求两个 random variables 之间的 correlation, 就是把它们都 center 到 zero-centered 的位置 (即投影到 L_0^2 space 上), 然后计算它们在 L_0^2 space 上的 cosine similarity.

此时我们看到 decomposition of variance:

Proposition 2.9 (两个 random variables 之和的 variance)

两个 random variables 之和的 variance 可分解成 variances 和 covariance:

$$\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y) + 2\text{Cov}(X, Y)$$



Proof

$$\text{Var}(X + Y) = \mathbb{E}[(X + Y)^2] - (\mathbb{E}[X + Y])^2 = \mathbb{E}[X^2] - (\mathbb{E}[X])^2 + \mathbb{E}[Y^2] - (\mathbb{E}[Y])^2 + 2(\mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y])$$

□

Remark

它其实这就是标准的 inner product space 上的向量平方公式:

$$\|X + Y\|_{L_0^2}^2 = \|X\|_{L_0^2}^2 + \|Y\|_{L_0^2}^2 + 2\langle X, Y \rangle_{L_0^2}$$

2.4 discrete random variables

Recall: discrete random variable 是指其 range a.s. 是 countable 的 random variable. (存在一个 countable set $S \subseteq \mathbb{R}$ 使得 $\mathbb{P}(X \in S) = 1$)

discrete RV 的 probability mass uncton (pmf):

$$p_X(x) := \mathbb{P}(X = x), \quad \forall x \in \mathbb{R}$$

就是 X 的 distribution P^X 对于 counting measure of range S 的 Radon-Nikodym derivative:

$$p_X = \frac{dP^X}{d\mu_S}$$

因为假设 X 的 range 是 $S = \{x_1, x_2, \dots\}$, 那么对于任意 Borel set B ,

$$\mathbb{P}^X(B) = \sum_{x_i \in B} \mathbb{P}(X = x_i) = \sum_{x_i \in B \cap S} p_X(x_i) = \int_A p_X(x) d\mu_S(x)$$

下面我们给出一些经典的 discrete random variable 的例子, 以及它们的 pmf 和 cdf.

2.4.1 Bernoulli distribution and Binomial distribution

Example 2.5 (Bernoulli distribution)

令 $\Omega := \{\omega_1, \omega_2\}$, $\mathcal{F} := 2^\Omega$.

令 $\mathbb{P}(\{\omega_1\}) = p$, $\mathbb{P}(\{\omega_2\}) = 1 - p$ 来表示这两个 singular 事件的概率.

令 $X(\omega_1) = 1$, $X(\omega_2) = 0$ 分别表示 success 和 failure.

那么显然可以计算:

$$\mathbb{P}(X = 0) = \mathbb{P}(\{\omega_2\}) = 1 - p, \quad \mathbb{P}(X = 1) = \mathbb{P}(\{\omega_1\}) = p$$

我们称 $(\Omega, \mathcal{F}, \mathbb{P})$ 为一个 Bernoulli probability space (它 model 了一个 Bernoulli trial, 即一个 random experiment with two possible outcomes: success 和 failure)

称 $X : \Omega \rightarrow \{0, 1\}$ 这个 random variable 为一个 **Bernoulli random variable**, 并称 X 的 distribution P^X 为一个 **Bernoulli distribution**, 写作

$$X \sim \text{Ber}(p)$$

这是最简单的 random variable 和 distribution 了. 它 model 的是: 比如我们 toss 一枚 biased coin, 以 p 的概率得到 heads (success), 以 $1 - p$ 的概率得到 tails (failure).

Proposition 2.10

如果 $X \sim \text{Ber}(p)$, 那么 $\mathbb{E}[X] = p$, $\text{Var}(X) = p(1 - p)$.

显然.

Example 2.6 (Binomial distribution)

我们 independently repeat n 次 Bernoulli trial, 每次 trial 的 success probability 都是 p .

考虑:

$$S := X_1 + X_2 + \dots + X_n$$

为 success 的总次数. 那么 S 是一个 discrete random variable $S : \Omega^n \rightarrow \mathbb{Z}_{\geq 0}$ 容易计算出 S 的 pmf:

$$p_S(k) = \mathbb{P}(S = k) = \binom{n}{k} p^k (1 - p)^{n-k}, \quad k = 0, 1, \dots, n$$

我们称 S 的 distribution P^S 为一个 **Binomial distribution**, 写作

$$S \sim \text{Bin}(n, p)$$

它 model 的是: 比如我们 toss 一枚 biased coin n 次, 得到 heads 的总次数.

Proposition 2.11

如果 $S \sim \text{Bin}(n, p)$, 那么 $\mathbb{E}[S] = np$, $\text{Var}(S) = np(1-p)$.

Proof

$$\mathbb{E}[X] = \sum_{k=1}^n k \cdot \mathbb{P}(X = k) = \sum_{k=1}^n k \cdot \binom{n}{k} p^k (1-p)^{n-k} = p(1-p)^{n-1} \sum_{k=1}^n k \cdot \binom{n}{k} \left(\frac{p}{1-p}\right)^{k-1}$$

由于

$$(1+t)^n = \sum_{k=0}^n \binom{n}{k} t^k \implies n(1+t)^{n-1} = \sum_{k=1}^n k \cdot \binom{n}{k} t^{k-1}$$

可以得到

$$\mathbb{E}[X] = p(1-p)^{n-1} \cdot n(1 + \frac{p}{1-p})^{n-1} = np$$

然后计算得 $\text{Var}(X) = np(1-p)$. 但是这是比较麻烦的方法. 也可以利用 $X = \sum_{i=1}^n X_i$, 其中 $X_i \sim \text{Ber}(p)$ i.i.d 这个事实来计算, 那么直接通过线性叠加 Bernoulli random variable 的 expectation 和 variance 就可以了. $\square$

2.4.2 Geometric distribution and Negative Binomial distribution**Example 2.7 (Geometric distribution)**

我们 perform independent Bernoulli trial, 每次 trial 的 success probability 都是 p .

考虑 random variable T 表示第一次 success 发生的 trial number. (也就是等于: 我们一直 trial, 直到第一次 success 发生, 那么这个 trial 的 number 就是 T).

那么 T 是一个 discrete random variable $T: \Omega^\infty \rightarrow \mathbb{Z}_{\geq 1}$.

容易计算出 T 的 pmf:

$$p_T(k) = \mathbb{P}(T = k) = (1-p)^{k-1}p, \quad k = 1, 2, \dots$$

我们称 T 的 distribution P^T 为一个 **Geometric distribution**, 写作

$$T \sim \text{Geom}(p)$$

它 model 的是: 比如我们 toss 一枚 biased coin, 第一次得到 heads 的 trial number.

Proposition 2.12

如果 $X \sim \text{Geom}(p)$, 那么 $\mathbb{E}[X] = 1/p$, $\text{Var}(X) = (1-p)/p^2$.

Proof

$$\mathbb{E}[X] = \sum_{k=1}^{\infty} k(1-p)^{k-1}p = p \sum_{k=1}^{\infty} k(1-p)^{k-1} = p \left(-\frac{d}{d(1-p)} \sum_{k=0}^{\infty} (1-p)^k \right) = -p - \frac{d}{dp} \frac{1}{1-(1-p)} = \frac{1}{p}$$

similarly, 可以计算得

$$\mathbb{E}[X^2] = \frac{2-p}{p^2}$$

因而

$$\text{Var}[X] = \mathbb{E}[X^2] - (\mathbb{E}[X])^2 = \frac{1-p}{p^2}$$

□

Example 2.8 (Negative Binomial distribution)

这是 Geometric distribution 的 generalization (但不完全一样).

我们 perform independent Bernoulli trial, 每次 trial 的 success probability 都是 p . (即 independent and identically distributed)

令 random variable T_r 表示第 r 次 success 发生之前的 failures 的数量. (也就是等于: 我们一直 trial, 直到第 r 次 success 发生, 那么这个 trial 的 number 就是 $T_r + r$, 因为 T_r 是 failures 的数量, 还要加上 $r - 1$ 个 success.).

那么 T_r 是一个 discrete random variable $T_r : \Omega^\infty \rightarrow \mathbb{Z}_{\geq 0}$.

容易计算出 T_r 的 pmf:

$$p_{T_r}(k) = \mathbb{P}(T_r = k) = \binom{k+r-1}{k} (1-p)^k p^r, \quad k = 0, 1, 2, \dots$$

这是因为: 最后一次 success 的位置是固定的. 我们要在前 $k + r - 1$ 次 trial 中选择 k 次作为 failures.

我们称 T_r 的 distribution P^{T_r} 为一个 **Negative Binomial distribution**, 写作

$$T_r \sim \text{NB}(r, p)$$

它 model 的是: 比如我们 toss 一枚 biased coin, 得到第 r 个 heads 之前会经历的 failures 的数量.

2.4.3 Poisson distribution


Example 2.9 (Poisson distribution) 考虑这一 pmf:

$$\mathbb{P}(X = k) = e^{-\lambda} \frac{\lambda^k}{k!}, \quad k = 0, 1, 2, \dots$$

我们称 X 的 distribution P^X 为一个 **Poisson distribution**, 写作

$$X \sim \text{Poi}(\lambda), \quad \lambda > 0$$

以 $\lambda = 3$ 为例画出 pmf 示意图:



Remark 当 $n \rightarrow \infty$ 时, $\text{Bin}(n, \lambda/n)$ 的 distribution 趋近于 $\text{Poi}(\lambda)$.

考虑 $X \sim B(n, \frac{\lambda}{n})$, 对于固定的 k :

$$\mathbb{P}(X = k) = \binom{n}{k} \left(\frac{\lambda}{n}\right)^k \left(1 - \frac{\lambda}{n}\right)^{n-k}$$

展开组合数 $\binom{n}{k}$:

$$\mathbb{P}(X = k) = \frac{n(n-1)\dots(n-k+1)}{k!} \cdot \frac{\lambda^k}{n^k} \cdot \left(1 - \frac{\lambda}{n}\right)^n \cdot \left(1 - \frac{\lambda}{n}\right)^{-k}$$

重组项:

$$\mathbb{P}(X = k) = \frac{\lambda^k}{k!} \cdot \underbrace{\frac{n(n-1)\dots(n-k+1)}{n^k}}_{(1)} \cdot \underbrace{\left(1 - \frac{\lambda}{n}\right)^n}_{(2)} \cdot \underbrace{\left(1 - \frac{\lambda}{n}\right)^{-k}}_{(3)}$$

其中, (1) 的 limit 是 1, (2) 的 limit 是 $e^{-\lambda}$, (3) 的 limit 是 1, 因而

$$\lim_{n \rightarrow \infty} \mathbb{P}(X = k) = e^{-\lambda} \frac{\lambda^k}{k!}$$

这个极限行为的意义是:

- λ 表示: 在一个固定时间/空间窗口内, 一个事件出现的平均次数的观测.
- 我们把这段时间分成 n 个小窗口, 将这个观测作为先验知识用来 model 这类事件实现的平均概率, 那么每个小窗口内事件出现的概率是 $p = \lambda/n$.
- 每个 $\text{Bin}(n, \lambda/n)$ 都表示: 在时间细分成 n 个小窗口的情况下, 这个事件出现的次数的分布. (注意不是在时间上的分布, 而是在次数上的分布)
- 当 $n \rightarrow \infty$ 时, 其意义: 基于连续时间的估计, 这个事件在原固定事件窗口内出现的次数的分布. 这就是 $\text{Poi}(\lambda)$ 的意义.

因而 Poisson distribution 的意义本质上是: 给定对一个事件在固定窗口下出现的平均次数的观测 (估计), 那么这个事件在这个窗口内出现 n 次 ($n = 0, 1, 2, \dots$) 的概率是多少?

所以 Poisson 分布, 即是根据一个事件在给定 windows 内发生次数的 expectation, 来估计这个事件在该 windows 内发生次数的分布的标准方法.

Remark

Further remark: Poisson distribution 的用途.

- 它是 model "大量级的小概率事件" 的通用模型.
即一段时间内, 一件事情的发生的概率非常小 ($p \ll 1$), 但是有很多机会发生 ($n \gg 1$). 比如放射性衰变.
- 现实世界中, 对于一些事情, 我们想要 model 其在一段时间内发生的总次数 (n) 和单次成功率 (p) 是很困难的. 比如统计今天路过百货大楼的总人数 (n), 以及每个人路过百货大楼时走进去的概率 (p). 但是我们很容易可以知道: $\lambda = np$ 的观测. 即: 每天平均有多少人走进百货大楼. 那么我们就可以用 Poisson distribution 来 model 这件事情在一天内发生的次数的分布.

Proposition 2.13

如果 $X \sim \text{Poi}(\lambda)$, 那么 $\mathbb{E}[X] = \lambda$, $\text{Var}(X) = \lambda$.



Proof recall e^x 的 Taylor expansion:

$$e^x = \sum_{k=0}^{\infty} \frac{x^k}{k!}$$

因而

$$\mathbb{E}[X] = \sum_{k=0}^{\infty} k e^{-\lambda} \frac{\lambda^k}{k!} = e^{-\lambda} \lambda \sum_{k=1}^{\infty} \frac{\lambda^{k-1}}{(k-1)!} = e^{-\lambda} \lambda e^{\lambda} = \lambda$$

similarly, 可以计算得

$$\mathbb{E}[X^2] = \lambda^2 + \lambda$$

因此,

$$\text{Var}(X) = \mathbb{E}[X^2] - (\mathbb{E}[X])^2 = \lambda$$

□

2.4.3.1 Poisson distribution 的 additivity

Theorem 2.7 (additivity of Poisson distribution)

如果 $X \sim \text{Poi}(\lambda_1)$, $Y \sim \text{Poi}(\lambda_2)$ are independent, 那么

$$X + Y \sim \text{Poi}(\lambda_1 + \lambda_2)$$



Remark 这个事实通过简单的计算即可得到.

但是值得一提的是, 我们之后会证明一个结论: 两个 independent 的 random variable 的 sum 的 distribution 是它们 convolution 的 distribution.

而 Poisson distribution 的 convolution 仍然是 Poisson distribution, 并且是 linear 的. 这就是 additivity of Poisson distribution 的本质原因.

2.5 continuous random variables

recall: 总而言之, continuous random variable 是指其 distribution $\mathbb{P}^X$ 对于 Lebesgue measure m 是 absolutely continuous 的 random variable, 等价于存在一个 pdf f_X 使得

$$F_X(x) = \int_{-\infty}^x f_X(y) dy$$

对于任意 x 都成立.

而由 $\mathbb{E}[X] = \int_{\Omega} X d\mathbb{P} = \int_{\mathbb{R}} x d\mathbb{P}^X = \int_{\mathbb{R}} x f_X(x) dx$ 可得

$$\mathbb{E}[X] = \int_{-\infty}^{+\infty} x f_X(x) dx, \quad \text{Var}(X) = \int_{-\infty}^{+\infty} (x - \mathbb{E}[X])^2 f_X(x) dx$$

这里还有一个额外的结论:

Proposition 2.14

对于任意的 measurable function $g : \mathbb{R} \rightarrow \mathbb{R}$, 都有

$$\mathbb{E}[g(X)] = \int_{-\infty}^{+\infty} g(x) f_X(x) dx$$



Proof

$$\mathbb{E}[g(X)] = \int_{\Omega} g(X(w)) d\mathbb{P}(w)$$

$$\begin{aligned}
&= \int_{\Omega} g \circ X \, d\mathbb{P} \\
&= \int_{\mathbb{R}} g \, d\mathbb{P}^X \\
&= \int_{-\infty}^{+\infty} g(x) f_X(x) \, dx
\end{aligned}$$

□

下面我们介绍一些常见的 continuous random variables, 以及它们的 pdf, cdf, expectation 和 variance.

2.5.1 uniform distribution: 最简单的 continuous RV

Def 2.14 (uniform distribution)

如果 $f_X(x) = \frac{1}{b-a}$ on (a, b) and 0 elsewhere, 那么我们称 X 的 distribution P^X 为一个 **uniform distribution**, 写作

$$X \sim U([a, b])$$





对于 uniform distribution, 很容易计算得:

$$F_X(x) = \frac{x-a}{b-a}, \quad \mathbb{E}[X] = \frac{a+b}{2}, \quad \text{Var}(X) = \frac{(b-a)^2}{12}$$

Example 2.10 (uniform distribution 的 pdf 和 cdf)

考虑 $X \sim U([a, b])$, 其 pdf 和 cdf 的图像如下:



2.5.2 exponential distribution: geometric distribution 的 continuous version

Exponential random variable model 的是一盏灯的 remaining lifetime. 它 assume: 任意时间, 这盏灯有一个 constant 的磨损速率.

假设它的磨损速率是 $\lambda = \lambda_X(t)$ for all t , 那么在任意时间 t 上:

$$\lambda_X(t) = \lim_{h \rightarrow 0^+} \frac{P(X \in (t, t+h])}{h} = \lim_{h \rightarrow 0^+} \frac{\mathbb{P}(t \leq X \leq t+h)}{h} \cdot \frac{1}{\mathbb{P}(X > t)} = \frac{f_X(t)}{1 - F_X(t)}$$

即 ODE:

$$\lambda = \frac{F'_X(t)}{1 - F_X(t)}$$

with initial condition $F_X(0) = 0$.

我们知道这个 ODE 的 solution 是:

$$F_X(t) = \begin{cases} 1 - e^{-\lambda t}, & t > 0 \\ 0, & t \leq 0 \end{cases}, \quad f_X(t) = \begin{cases} \lambda e^{-\lambda t}, & t > 0 \\ 0, & t \leq 0 \end{cases}$$

Def 2.15 (exponential distribution)

我们称 X 为一个 **exponential random variable** with parameter λ , 如果它的 pdf is given by:

$$f(x) = \begin{cases} \lambda e^{-\lambda x}, & x > 0 \\ 0, & x \leq 0 \end{cases}$$

写作

$$X \sim \text{Exp}(\lambda)$$



刚才已经计算出, exponential random variable 的 distribution 为

$$F_X(x) = \begin{cases} \int_{-\infty}^x f(t) dt = \lambda \int_0^x e^{-\lambda t} dt = 1 - e^{-\lambda x}, & x > 0 \\ 0, & x < 0 \end{cases}$$

容易验证, $F_X(x) = 0$ when $x \rightarrow -\infty$, 以及 $F_X(x) \rightarrow 1$ when $x \rightarrow \infty$

计算其 expectation:

$$\mathbb{E}[X^n] = \lambda \int_0^{\infty} x^n e^{-\lambda x} dx \quad (2.5)$$

$$= - \int_0^{\infty} x^n (e^{-\lambda x})' dx \quad (2.6)$$

$$= 0 + \int_0^{\infty} n x^{n-1} e^{-\lambda x} dx \quad (2.7)$$


$$= \frac{n}{\lambda} \mathbb{E}(X^{n-1}) \quad (2.8)$$

并 notice: $\mathbb{E}[X^0] = \mathbb{E}[1] = 1$. 因而 recursively get:


$$\mathbb{E}[X^n] = \frac{n!}{\lambda^n}$$

即: $\mathbb{E}[X] = \frac{1}{\lambda}$, $\mathbb{E}[X^2] = \frac{2}{\lambda^2}$, ... 从而:

$$\text{Var}[X] = \frac{2}{\lambda^2} - \frac{1}{\lambda^2} = \frac{1}{\lambda^2}$$



(a) pdf



(b) cdf

Remark exponential 随机变量是 geometric 随机变量的 continuous analogue. 因为 geometric random variable 是假设一个事件在每个时间点以 constant 的概率发生, 用来 model 它第一次发生的时间;

而 exponential random variable 其实也是, 只是 on a continuous time scale: 它假设的 constant 损坏率其实 implies: 在任意时间, 如果灯还没坏, 那么灯此刻坏掉的概率是 constant 的.

Theorem 2.8 (memoryless property of exponential distribution)

任意 continuous RV,

$$\mathbb{P}(X > b + t \mid X > b) = \mathbb{P}(X > t) \iff X \text{ is an exponential random variable}$$



Proof 简单而言

$$P(X > b + t \mid X > b) = P(X > t) \quad (2.9)$$

$$\iff P(X > b + t) = P(X > t)P(X > b) \quad (2.10)$$

$$\iff X \text{ exponential} \quad (2.11)$$

□

因而对于 geometric RV 的 pmf, 当我们把时间间隔 (discrete time interval) 变得越来越小, 这一行为的极限就变为了 exponential RV 的 pdf.

这是一个很自然的 limit behavior, 此处不验证了.

Example 2.11 假设我们有一个 storage battery, 它的 lifetime 是 exponentially distributed 的, 并且 average 为 10 hours. Suppose 我们想要 use this battery for 5 hours for.

计算: probability of finishing the task, if:

(a) 使用一个 new battery

(b) 使用一个已经用过 2 hours 的 battery

Sol.

$$\mathbb{E}[X] = 10 = \frac{1}{\lambda} \implies \lambda = \frac{1}{10}$$

如果我们使用一个 new battery, 则 want: $P(X > 5) = 1 - P(X < 5) = 1 - F_X(5) = e^{-\frac{1}{2}}$ 如果我们使用一个用过 2 hours 的 battery, 则 want:

$$P(X > 5 + 2 \mid X > 2) = \frac{e^{-(5+2)\lambda}}{e^{-2\lambda}} = e^{-5\lambda} = e^{-\frac{1}{2}}$$

Notice:

$$P(X > 5) = P(X > 5 + 2 \mid X > 2)$$

2.5.3 Gamma distribution: negative binomial distribution 的 continuous version

recall Gamma 函数:

$$\Gamma(\alpha) = \int_0^\infty x^{\alpha-1} e^{-x} dx$$

这个函数有一个重要的性质:

$$\Gamma(\alpha + 1) = \alpha \Gamma(\alpha)$$

因而对于 $n \in \mathbb{N}$, 我们有:

$$\Gamma(n) = (n-1)!$$

Gamma 函数就是 factorial 函数的 continuous generalization.

Def 2.16 (Γ -distribution)

如果 continuous random variable X 的 pdf 是:

$$f_X(x) = \begin{cases} \frac{\lambda^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\lambda x}, & x > 0, \\ 0, & x \leq 0 \end{cases}$$

那么我们称 X 服从 Γ **distribution**, 写作

$$X \sim \Gamma(\alpha, \lambda)$$

其中 $\alpha > 0$ 称为 shape parameter, $\lambda > 0$ 称为 rate parameter.



Γ distribution 的 cdf 这样求: for $a \geq 0$,

$$\begin{aligned} F_X(a) &= \int_{-\infty}^a f_X(x) dx = \int_0^a \frac{\lambda^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\lambda x} dx \\ &= \frac{1}{\Gamma(\alpha)} \int_0^{\lambda a} t^{\alpha-1} e^{-t} dt \end{aligned}$$

and for $a < 0$, $F_X(a) = 0$.

Expectation:

$$\begin{aligned} \mathbb{E}[X] &= \frac{1}{\Gamma(\alpha)} \int_0^\infty (\lambda x)^{\alpha-1} \lambda e^{-\lambda x} dx \\ &= \frac{1}{\lambda \Gamma(\alpha)} \int_0^\infty x^\alpha e^{-x} dx \\ &= \frac{\Gamma(\alpha+1)}{\lambda \Gamma(\alpha)} = \frac{\alpha}{\lambda} \end{aligned}$$

(since $\Gamma(\alpha+1) = \alpha \Gamma(\alpha)$.) 同理我们可以计算得: $\mathbb{E}[X^2] = \frac{\alpha(\alpha+1)}{\lambda^2}$ 从而

$$\text{Var}[X] = \mathbb{E}[X^2] - (\mathbb{E}[X])^2 = \frac{\alpha(\alpha+1)}{\lambda^2} - \frac{\alpha^2}{\lambda^2} = \frac{\alpha}{\lambda^2}$$

容易发现: 当 $\alpha = 1$ 时, Γ distribution 就退化成了 exponential distribution.

$$\Gamma(1, \lambda) = \text{Exp}(\lambda)$$

而当 α 是一个正整数 n 时, Γ distribution 实际就是 n 个 independent exponential distribution 的 sum:

Proposition 2.15 (Gamma distribution 即是 independent exponential distribution 的 sum)

Let $X_1, X_2, \dots, X_n \sim \text{Exp}(\lambda)$ be i.i.d., 则


$$\Gamma(n, \lambda) = \sum_{i=1}^n X_i$$



Proof 证明这一结论除了硬算之外, 更快的方法是通过 moment generating function. //TODO □

Remark Gamma distribution 即多个 i.i.d. exponential distribution 的 sum; 而我们知道 exponential distribution 是 geometric distribution 的 continuous analogue; 因而 **Gamma distribution 也是 negative binomial distribution 的 continuous analogue.**

考虑固定 rate parameter $\lambda = 1$, 不同 shape parameter α 的 Gamma distribution:



- 当 $\alpha = 1$ 时, Gamma 分布退化为指数分布, pdf 单调递减;
- 随着 α 增大, pdf 从 0 处开始上升, 形成驼峰形状, 并逐渐向右平移;
- cdf 随 α 增大而上升变缓, 表示分布的右尾变长。

2.5.4 normal random variables: 最重要的 continuous RV, 任意 RV 的叠加极限

Def 2.17

我们称 X is **normally distributed with parameter μ and σ** , if the pdf of X is given by:

$$p(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

写作:

$$X \sim \mathcal{N}(\mu, \sigma^2)$$

特别地, 当 $\mu = 0, \sigma = 1$ 时,

$$X \sim \mathcal{N}(0, 1)$$

被称为 **standard normal distribution**.



- 验证其为 valid pdf:

我们首先验证 standard normal distribution. 令:

$$I := \int_0^\infty e^{-\frac{y^2}{2}} dy$$

则

$$\begin{aligned} I^2 &= \int_0^\infty e^{-\frac{y^2}{2}} dy \cdot \int_0^\infty e^{-\frac{x^2}{2}} dx \\ &= \int_{\mathbb{R}_{\geq 0}^2} e^{-\frac{x^2+y^2}{2}} dx dy \\ &= \int_0^{\pi/2} \int_0^\infty e^{-\frac{r^2}{2}} r dr d\theta \\ &= \int_0^{\pi/2} \left(-e^{-\frac{r^2}{2}} \Big|_0^\infty \right) d\theta \\ &= \int_0^{\pi/2} 1 d\theta = \frac{\pi}{2} \end{aligned}$$

从而得到 $I = \frac{\sqrt{2\pi}}{2}$. 因而 $\int_{-\infty}^\infty e^{-\frac{x^2}{2}} dx = \sqrt{2\pi}$, 因而 $\int_{\mathbb{R}} p(x) dx = 1$.

从而对于任意的 μ 和 σ , 通过 change of variable formula 易得 $\int_{\mathbb{R}} p(x) dx = 1$.

- 计算其 expectation 和 variance:

我们只需要计算 standard normal distribution 的 expectation 和 variance, 然后通过 expectation 的 linearity 和 variance 的 scale invariance 来计算.

令 $X \sim \mathcal{N}(0, 1)$. Then

$$\mathbb{E}[X] = \frac{1}{\sqrt{2\pi}} \int_{\mathbb{R}} x e^{-\frac{x^2}{2}} dx = 0$$

因为这是一个 **odd function**. 从而

$$\begin{aligned} \mathbb{E}[X^2] &= \frac{1}{\sqrt{2\pi}} \int_{\mathbb{R}} x^2 e^{-\frac{x^2}{2}} dx = \frac{1}{\sqrt{2\pi}} \int_{\mathbb{R}} x (x e^{-\frac{x^2}{2}}) dx = \frac{1}{\sqrt{2\pi}} \int_{\mathbb{R}} x (e^{-\frac{x^2}{2}})' dx \\ &= -\frac{1}{\sqrt{2\pi}} x e^{-\frac{x^2}{2}} \Big|_{-\infty}^{\infty} + \frac{1}{\sqrt{2\pi}} \int_{\mathbb{R}} e^{-\frac{x^2}{2}} dx = 0 + 1 = 1 \end{aligned}$$

从而:

$$\text{Var}(X) = 1$$

For general normally distributed Y , 我们知道了 $X := \frac{Y-\mu}{\sigma}$ 的 $\mathbb{E}[X] = 0$, $\text{Var}(X) = 1$, 因而

$$\mathbb{E}[Y] = \mathbb{E}[\sigma X + \mu] = \mu$$

and

$$\text{Var}(Y) = \text{Var}(\sigma X + \mu) = \mathbb{E}[(\sigma X + \mu - \mu)^2] = \mathbb{E}(\sigma^2 X^2) = \sigma^2 \mathbb{E}[X^2] = \sigma^2$$

对于多个 i.i.d. normally distributed X ,

$$\mathbb{E}[X^k] = \frac{1}{\sqrt{2\pi}} \int_{\mathbb{R}} x^k e^{-\frac{x^2}{2}} dx$$

For k odd, it is 0.

For k even:

$$\begin{aligned} \mathbb{E}[X^k] &= \frac{1}{\sqrt{2\pi}} \int_{\mathbb{R}} x^{k-1} (x e^{-\frac{x^2}{2}}) dx \\ &= -\frac{1}{\sqrt{2\pi}} \int_{\mathbb{R}} x^{k-1} (e^{-\frac{x^2}{2}})' dx \\ &= 0 + \frac{1}{\sqrt{2\pi}} \int_{\mathbb{R}} (x^{k-1})' e^{-\frac{x^2}{2}} dx \\ &= \frac{k-1}{\sqrt{2\pi}} \int_{\mathbb{R}} x^{k-2} e^{-\frac{x^2}{2}} dx \\ &= (k-1) \mathbb{E}[X^{k-2}] \end{aligned}$$

从而:

$$\mathbb{E}[X^k] = \begin{cases} 0, & k = 2j - 1 \\ (2j-1)(2j-3) \cdots 1 = \frac{(2j)!}{2^j j!}, & k = 2j \end{cases}$$

- 其 cdf:

$$\Phi(a) := F_X(a) = \int_{(-\infty, a]} \rho(x) dx = \frac{1}{\sqrt{2\pi}} \int_{(-\infty, a]} e^{-\frac{x^2}{2}} dx$$

我们在微积分中知道, 这个 integral 没有 closed form solution. 因而我们只能给出数值 approximation. Important numerical values:

$$\Phi(-3) \approx 0.0013; \quad \Phi(-2) \approx 0.023; \quad \Phi(-1) \approx 0.159$$

Note 由于 ρ (std) 是一个 even function, 有 $P(X < -1) = P(X > 1)$ 因而

$$P(X \text{ is one std dev from mean}) = 2(P(X < -1)) = 2\Phi(-1) \approx 0.32 = 32\%$$

Similarly,

$$P(X \text{ is two std dev from mean}) \approx 0.046 = 4.6\%$$

$$P(X \text{ is three std dev from mean}) \approx 0.0026 = 0.26\%$$

为什么 normal random variables 非常重要: 因为有一个 universality property called **central limit theorem**. 之后的章节我们会展开讨论:

任意的 random variable, 只要 expectation 和 variance 都是 finite 的, 那么它们的叠加极限都会服从 normal distribution.

这里我们先给出一个 special case of central limit theorem:

Theorem 2.9 (DeHavre's Central limit theorem for binomial distribution)

令 $S_n \sim \text{Bin}(n, p)$, 则

$$\lim_{n \rightarrow \infty} P\left(\frac{S_n - \mathbb{E}(S_n)}{\sigma(S_n)} \in (a, b)\right) = \Phi(b) - \Phi(a) = \frac{1}{\sqrt{2\pi}} \int_{(a,b)} e^{-\frac{x^2}{2}} dx$$



(Proof: later chapters.)

Example 2.12 Toss a million times 一个 fair coin. Approximate the prob that we get more than 501000 heads:

$$\mathbb{E}(S_{1000000}) = np = 500000$$

$$\sigma(S_{1000000}) = \sqrt{npq} = 500$$

因而:

$$\begin{aligned} \mathbb{P}(S_{1000000} > 501000) &= \mathbb{P}(S_{1000000} - \mathbb{E}(S_{1000000}) > 1000) \\ &= \mathbb{P}\left(\frac{S_{1000000} - \mathbb{E}(S_{1000000})}{\sigma(S_{1000000})} > \frac{1000}{500}\right) \\ &\approx 1 - \Phi(2) = \Phi(-2) \approx 0.159 \end{aligned}$$

除此之外 need to mention: Poisson distribution 当 $\lambda \rightarrow \infty$ 时, 也得到 normal distribution.

这并不是一个令人惊讶的事情. 也可以用 central limit theorem 来解释. 因为 recall: Poisson distribution 有一个很重要的 property: additivity. 因而 $\lambda \rightarrow \infty$ 也可以看作 n 个 i.i.d. Poisson distribution 的 sum 在 $n \rightarrow \infty$ 时的极限行为, 从而通过 central limit theorem 得到 normal distribution.

2.5.5 summary of discrete and continuous variables examples

distribution	pmf / pdf	cdf	$\mathbb{E}[X]$	$\text{Var}(X)$	meaning
Ber(p)	$\mathbb{P}(X = 1) = p,$ $\mathbb{P}(X = 0) = 1 - p$	$F(x) = 1 - p, 0 \leq x < 1$	p	$p(1 - p)$	一次 Bernoulli trial (unfair coin) 的结果
Bin(n, p)	$\mathbb{P}(X = k) = \binom{n}{k} p^k (1 - p)^{n-k},$ $k = 0, \dots, n$	$F(k) = \sum_{j=0}^{\lfloor k \rfloor} \binom{n}{j} p^j (1 - p)^{n-j}$	np	$np(1 - p)$	n 次 i.i.d. Bernoulli trials 中的成功次数
Geom(p)	$\mathbb{P}(X = k) = (1 - p)^{k-1} p, k \geq 1$	$F(k) = 1 - (1 - p)^k$	$\frac{1}{p}$	$\frac{1-p}{p^2}$	Bernoulli trial 第一次成功所需的试验次数
NB(r, p)	$\mathbb{P}(X = k) = \binom{k+r-1}{k} (1 - p)^k p^r, k \geq 0$	$F(k) = \sum_{j=0}^k \binom{j+r-1}{j} (1 - p)^j p^r$	$\frac{r(1-p)}{p}$	$\frac{r(1-p)}{p^2}$	Bernoulli trial 在 r 次成功之前观察到的失败次数
Poi(λ)	$\mathbb{P}(X = k) = e^{-\lambda} \frac{\lambda^k}{k!}, k \geq 0$	$F(k) = \sum_{j=0}^k e^{-\lambda} \frac{\lambda^j}{j!}$	λ	λ	fixed window (time/space) 下某一事件的计数
$U([a, b])$	$f(x) = \frac{1}{b-a}, a \leq x \leq b$	$F(x) = \begin{cases} 0, & x < a \\ \frac{x-a}{b-a}, & a \leq x \leq b \\ 1, & x > b \end{cases}$	$\frac{a+b}{2}$	$\frac{(b-a)^2}{12}$	uniform choice on an interval
Exp(λ)	$f(x) = \lambda e^{-\lambda x}, x \geq 0$	$F(x) = \begin{cases} 0, & x \leq 0 \\ 1 - e^{-\lambda x}, & x > 0 \end{cases}$	$\frac{1}{\lambda}$	$\frac{1}{\lambda^2}$	固定平均发生率下, 某事件第一次发生要等多久
$\Gamma(\alpha, \lambda)$	$f(x) = \frac{\lambda^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\lambda x}, x \geq 0$	$F(x) = \frac{1}{\Gamma(\alpha)} \int_0^{\lambda x} t^{\alpha-1} e^{-t} dt$	$\frac{\alpha}{\lambda}$	$\frac{\alpha}{\lambda^2}$	α 个 i.i.d. exponential distributions 的和 (固定平均发生率下, 第 α 次事件出现前要等多久)
$N(\mu, \sigma^2)$	$f(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp(-(x - \mu)^2 / 2\sigma^2)$	no elementary closed form	μ	σ^2	大量微小独立扰动 (测量误差/自然波动) 叠加后的结果