Module 3 joint and conditional distributions

3.1 random vector and joint distributions

3.1.1 random vector

Def 3.1 (random vector)

对于 prob space $(\Omega, \mathcal{F}, P)$, 一个 function $\mathbf{X}: \Omega \to \mathbb{R}^n$ 如果是一个 $(\mathcal{F}, \mathcal{B}(\mathbb{R}^n))$-measurable function, 则称它为一个 n-dimensional random variable, 或者 n-dimensional random vector.
通常我们将 random vector 写成分量形式

$$\mathbf{X}(\omega) = (X_1(\omega), X_2(\omega), \ldots, X_n(\omega))^T$$

♣

random vector 相当于在一个 prob space 上, 考虑多个重新分配 mass 的方法, 并把它们并列起来.

Proposition 3.1 (由 n 个 random variable 构成的 vector 是一个 random vector)

令 $X_1, X_2, \cdots, X_n$ 是定义在**同一个 prob space** $(\Omega, \mathcal{F}, \mathbb{P})$ 上的 n 个 random variables. 则函数 $\mathbf{X}: \Omega \to \mathbb{R}^n$ defined by

$$\omega \mapsto (X_1(\omega), X_2(\omega), \cdots, X_n(\omega))^T$$

是一个 random vector.

♠

Proof 我们在 measure theory 中证明过: 对于任意的 finite seq of Borel measureable functions $(f_i: \Omega \to \mathbb{R})_{i=1}^k$, 其各作为一个维度组成的函数 $f = (f_1, \cdots, f_k)$ 也是一个 Borel measurable function (from Ω 到 $\mathbb{R}^k$).

Proposition 3.2 (一个 random vector 的每个分量都是一个 random variable)

令 $\mathbf{X} = (X_1, X_2, \cdots, X_n)^T$ 是一个 random vector. 则对于任意 i, X_i 都是一个 random variable.

♠

Proof 对于 $\mathbf{X}: \Omega \to \mathbb{R}^n$ 是 $(\mathcal{F}, \mathcal{B}(\mathbb{R}^n))$-measurable, 我们可以将第 i 个分量 X_i 看作是 composition of two maps:

$$X_i = \pi_i \circ \mathbf{X}$$

其中 $\pi_i: \mathbb{R}^n \to \mathbb{R}$ projection map $\pi_i(x_1, \ldots, x_n) = x_i$.
由于 projection map π_i 是一个 Borel measurable function, 我们可以得出: $X_i = \pi_i(\mathbf{X})$ 也是一个 Borel measurable function, 也就是一个 random variable.

Remark 上两条 propositions 说明了一个事情: random vectors 和其分量 random variables 完全相互决定.

- **random variables 组合起来一定是一个 random vector.**
- **random vector 拆开每个分量一定是 random variable.**

因而, 研究一个 random vector 也就相当于研究分量 random variables 之间的关系.
这一章节我们会从 random vector 的性质 (比如 **joint distribution 和 marginal distribution, conditional distribution**) 出发, 研究分量 random variables 之间的关系.

(但是注意: 前提是这些 random variables 必须定义在同一个 prob space 上. 也就是, 它们的 base probability measure 一定相同. 如果我们考虑不同 prob space 上的 random variables 的话, 那它们没有一个公共的 base probability measure, 很难说它们之间有什么关系. 这种情况下, 我们需要 coupling: 构造一个新的 prob space (说白了就是 product space), 让这两个 random variables 都有一个新 version. 这一问题我们之后再讨论.)

3.1.2 joint distribution

Def 3.2 (joint distribution and joint cdf)

令 $X_1, \cdots, X_n$ 为 RV from the same prob space. 即 $\mathbf{X} := (X_1, \cdots, X_n)$ 是一个 random vector.
我们称 $\mathbb{P}^{\mathbf{X}} : \mathbb{R}^n \to \mathbb{R}$ defined by

$$\mathbb{P}^{\mathbf{X}}(B) = \mathbb{P}(\mathbf{X}^{-1}(B)), \quad \forall B \in \mathcal{B}(\mathbb{R}^n)$$

为 $X_1, \cdots, X_n$ 的 **joint distribution**.
而我们称 $F_{\mathbf{X}} = F_{X_1,\cdots,X_n} : \mathbb{R}^n \to \mathbb{R}$ defined by

$$F_{\mathbf{X}}(x_1, \cdots, x_n) = \mathbb{P}(X_1 \le x_1, \cdots, X_n \le x_n)$$

(即 $\mathbb{P}^{\mathbf{X}}$ restricted to the set of rectangles $\{(-\infty, x_1] \times \cdots \times (-\infty, x_n] : (x_1, \cdots, x_n) \in \mathbb{R}^n\}$) 为它们的 **joint distribution function (或称 joint cdf)**. ♣

joint distribution 的定义已经包括了如何从多个 random variables 的 distributions 得到一个 joint distribution. 而, 我们也可以从一个 joint distribution 的 limit behavior 得到每个 random variable 分量的 distributions, 称之为 marginal distribution:

Def 3.3 (marginal distribution)

令 $\mathbf{X} = (X_1, \cdots, X_n)^T$ 是一个 random vector. 则对于任意 i, X_i 的 distribution $\mathbb{P}^{X_i}$ 被称为 $\mathbf{X}$ 的第 i 个分量的 **marginal distribution**. ♣

我们以 $\mathbb{R}^2$ 为例. 得出的结论可以推广到 $\mathbb{R}^n$.

Proposition 3.3 (通过 joint distribution 的 limit behavior 得到 marginal distribution)

令 $\mathbf{X} = (X_1, X_2)^T$ 是一个 random vector. 则对于任意 $x \in \mathbb{R}$, 有

$$\mathbb{P}(X_1 \le x) = \lim_{y \to \infty} F_{\mathbf{X}}(x, y)$$

X_2 的 marginal distribution 也可以通过同样的方法得到.
此外, joint distribution 有其他明显的 limit behaviors:

- $$\lim_{x \to -\infty} F(x, y) = \lim_{y \to -\infty} F(x, y) = 0$$
- $F_{\mathbf{X}}$ 对于每个维度都是 increasing 且 right-continuous 的.
- $$\mathbb{P}(X \le x, Y \le y) = \lim_{z \uparrow y} F(x, z) = \lim_{z \uparrow x} F(z, y) = \lim_{z_1 \uparrow x, z_2 \uparrow y} F(z_1, z_2)$$

- $$\mathbb{P}(x_1 \le X \le x_2, y_1 \le Y \le y_2) = F(x_2, y_2) - F(x_1, y_2) = F(x_2, y_1) + F(x_1, y_1)$$ ♠

Remark 最后一条: 右边相当于

$$\mathbb{P}(x_1 < X < x_2, Y < y_2) - \mathbb{P}(x_1 < X < x_2, Y < y_1)$$

因而成立.

discrete random vector 很容易处理. 我们可以直接定义 joint pmf. 而 continuous random vector 需要展开讨论. 接下来我们讲单独讨论 continuous random vector 的 joint distribution.

3.1.3 condinuous joint cdf 与 joint pdf

recall: 一个随机变量 X 被称为一个 continuous random variable, 如果它的 cdf 是 absolutely continuous 的. 这个条件也等价于, 存在一个函数 $f_X : \mathbb{R} \to [0, \infty)$ 使得

$$F_X(x) = \int_{-\infty}^{x} f_X(t)\, dt$$

这个定义可以 generalize 到 random vector 上.

Def 3.4 (continuous random vector 和 continuous joint cdf)

对于 random vector $\mathbf{X} = (X_1, \cdots, X_n)^T$ 如果 $\mathbb{P}^{\mathbf{X}} \ll \lambda^n$, 即存在一个函数 $f_{\mathbf{X}} : \mathbb{R}^n \to [0, \infty)$ 使得对于任意 Borel set $B \subseteq \mathbb{R}^n$, 有

$$\mathbb{P}^{\mathbf{X}}(B) = \int_B f_{\mathbf{X}}(x_1, \cdots, x_n)\, d\lambda^n(x_1, \cdots, x_n)$$

则称 $\mathbf{X}$ 是一个 **continuous random vector**.

注意: 由于是在 $\mathbb{R}^n$ 上, 这等价于存在一个函数 $f_{\mathbf{X}} : \mathbb{R}^n \to [0, \infty)$ 使得对于任意 $x_1, \cdots, x_n$, 有

$$F_{\mathbf{X}}(x_1, \cdots, x_n) = \int_{-\infty}^{x_1} \cdots \int_{-\infty}^{x_n} f_{\mathbf{X}}(t_1, \cdots, t_n)\, dt_n \cdots dt_1$$

♣

Remark 这个函数 $f_{\mathbf{X}}$ 就是 continuous random vector $\mathbf{X}$ 的 **joint probability density function (joint pdf).** 它是 joint distribution measure $\mathbb{P}^{\mathbf{X}}$ 对于 Lebesgue measure λ^n 的 Radon-Nikodym derivative:

$$\frac{d\mathbb{P}^{\mathbf{X}}}{d\lambda^n} = f_{\mathbf{X}}$$

Remark 我们已经知道, 只要存在导数 $f_{\mathbf{X}}$ 可以对于任意 $\mathbf{x} \in \mathbb{R}^n$ 还原出 joint cdf $F_{\mathbf{X}}$ 的值, 那么 $f_{\mathbf{X}}$ 就是 joint pdf, 这个 random vector 就是一个 continuous random vector.

那么这个还原积分的计算可以任意换序吗?

显然是可以的. 因为 recall **Fubini's theorem**: 只要 f 绝对可积, 即 $\int_{\mathbb{R}^n} |f|\, d\lambda^n < \infty$, 那么对于任意的 permutation σ of $\{1, 2, \cdots, n\}$, 我们都可以将积分的顺序换成

$$\int_{-\infty}^{x_{\sigma(1)}} \cdots \int_{-\infty}^{x_{\sigma(n)}} f(t_1, \cdots, t_n)\, dt_{\sigma(n)} \cdots dt_{\sigma(1)}$$

而我们知道, f 一定是非负的, 而且积分一定是 1, 因而可以任意换序积分.

这就很舒服. 这也给出了 margin distribution 的计算方法: 只要对 joint pdf $f_{\mathbf{X}}$ 在其他维度上积分掉就行了.

Remark 注意: **多个 continuous random variables 的 joint distribution 不一定是 continuous 的.** 反例: 考

虑 random vector $\mathbf{X} = (X, X)^T$ where $X \sim \text{Uniform}(0,1)$ 则 $\mathbb{P}((X,X) \in \{y = x\}) = 1$. 而注意, $\{y = x\}$ 在 $\mathbb{R}^2$ 中的 Lebesgue measure 为 0, 而 absolute continuity 要求: 对于一个零测集, 其 $\mathbb{P}^{\mathbf{X}}$ 测度也必须是 0 (这是 $\mathbb{P}^{\mathbf{X}} \ll \lambda^n$ 的标准定义), 因而 joint distribution 不是 continuous 的.

Proposition 3.4 (joint pdf 和 joint cdf 的性质)

令 $\mathbf{X} = (X_1, \cdots, X_n)^T$ 是一个 continuous random vector, 则它的 joint pdf $f_{\mathbf{X}}$ 和 joint cdf $F_{\mathbf{X}}$ 有以下性质:

- $f_{\mathbf{X}} \geq 0$ a.e. 并且 $\int_{\mathbb{R}^n} f_{\mathbf{X}}\, d\lambda^n = 1$.
- (如果一个集合 A 有一个零测维度, 那么 $\mathbb{P}^{\mathbf{X}}(A) = 0$)
$$\mathbb{P}(X_1 = x_1, x_2 \leq X_2 \leq x_2' \cdots, x_n \leq X_n \leq x_n') = 0$$
- 每个 X_i 的 marginal distribution 也是 (absolutely) continuous 的, 并且
$$f_{X_i}(x) = \int_{\mathbb{R}^{n-1}} f_{\mathbf{X}}(t_1, \cdots, t_{i-1}, x, t_{i+1}, \cdots, t_n)\, dt_1 \cdots dt_{i-1} dt_{i+1} \cdots dt_n$$
例如,
$$f_X(x) = \int_{-\infty}^{\infty} f_{\mathbf{X}}(x, y)\, dy$$
- 对每个 $x_1, \cdots, x_n \in \mathbb{R}$, 都可以通过偏导数从 joint cdf 得到 joint pdf (这个偏导数一定 (a.e.) 存在):
$$f_{\mathbf{X}}(x_1, \cdots, x_n) = \frac{\partial^n}{\partial x_1 \cdots \partial x_n} F_{\mathbf{X}}(x_1, \cdots, x_n)$$
并且 by Fubini's theorem 可以 (a.e.) 任意换序:
$$\frac{\partial^n}{\partial x_{\sigma(1)} \cdots \partial x_{\sigma(n)}} F_{\mathbf{X}} \overset{a.e.}{=} f_{\mathbf{X}}$$

Proof

- 由于 $f_{\mathbf{X}}$ 是 $\mathbb{P}^{\mathbf{X}}$ 对于 λ^n 的 Radon-Nikodym derivative, 因为任何 Borel 集 B 都有 $P^{\mathbf{X}}(B) \geq 0$, 假设存在一个集合 $A \in \mathcal{B}(\mathbb{R}^n)$ 使得在其上 $f_{\mathbf{X}} < 0$ 且 $\lambda^n(A) > 0$, 那么根据积分定义
$$\mathbb{P}^{\mathbf{X}}(A) = \int_A f_{\mathbf{X}}\, d\lambda^n < 0$$
因而反证得 $f_{\mathbf{X}} \geq 0$ a.e.
并且
$$\int_{\mathbb{R}^n} f_{\mathbf{X}}\, d\lambda^n = \mathbb{P}^{\mathbf{X}}(\mathbb{R}^n) = 1$$
- natural.
- 即 marginal distribution 的定义在 continuous case 中的展开
- by Fubini's theorem, 以及 joint cdf 的定义.

Example 3.1 考虑
$$f_{X,Y}(x,y) = \begin{cases} ce^{-x}e^{-2y}, & \text{if } x, y > 0 \\ 0, & \text{otherwise} \end{cases}$$

Find c 使得这是一个合法的 joint pdf, 并且计算 X 和 Y 的 marginal pdfs, 以及 $\mathbb{P}(X > 1, Y < 1)$.

Sol. 我们需要

$$c\left(\int_0^\infty e^{-x}dx\right)\left(\int_0^\infty e^{-2y}dy\right)=1$$

evaluate 这两个积分:

$$\int_0^\infty e^{-x}dx=\left[-e^{-x}\right]_0^\infty=1,$$

$$\int_0^\infty e^{-2y}dy=\left[-\frac{1}{2}e^{-2y}\right]_0^\infty=\frac{1}{2}$$

因为 c 必须为 2.

计算 X 的 marginal pdf:

$$f_X(x)=\int_0^\infty 2e^{-x}e^{-2y}dy=2e^{-x}\left[-\frac{1}{2}e^{-2y}\right]_0^\infty=e^{-x}$$

然后计算 Y 的 marginal pdf:

$$f_Y(y)=\int_0^\infty 2e^{-x}e^{-2y}dx=2e^{-2y}\left[-e^{-x}\right]_0^\infty=2e^{-2y}$$

最后计算 $\mathbb{P}(X>1,Y<1)$:

$$\mathbb{P}(X>1,Y<1)=\int_1^\infty\int_0^1 2e^{-x}e^{-2y}dydx=\left(\int_1^\infty e^{-x}dx\right)\left(\int_0^1 2e^{-2y}dy\right)$$

这两个定积分分别为:

$$\int_1^\infty e^{-x}dx=\left[-e^{-x}\right]_1^\infty=e^{-1},$$

$$\int_0^1 2e^{-2y}dy=\left[-e^{-2y}\right]_0^1=1-e^{-2}$$

因而

$$\mathbb{P}(X>1,Y<1)=e^{-1}(1-e^{-2})=e^{-1}-e^{-3}$$

Theorem 3.1

对于 continuous random vector $\mathbf{X}=(X_1,\cdots,X_n)^T$, 取任意 Borel measurable function $g:\mathbb{R}^n\to\mathbb{R}$, 则 $g(\mathbf{X})$ 是一个 random variable, 并且如果 $\mathbb{E}[|g(\mathbf{X})|]<\infty$, 则, 则

$$\mathbb{E}[g(\mathbf{X})]=\int_{\mathbb{R}^n}g(\mathbf{x})f_{\mathbf{X}}(\mathbf{x})\,d\lambda^n(\mathbf{x})$$

♡

Example 3.2 Let (X,Y) be a two-dimensional random variable with joint density function

$$f_{X,Y}(x,y)=\begin{cases}1, & 0<\frac{y}{2}<x<1\\ 0, & \text{otherwise}\end{cases}$$

(a) 求 marginal density f_Y

(b) 计算概率 $\mathbb{P}(X=1/2)$ 和 $\mathbb{P}(X+Y\le 3/2)$

Sol.

(a) 对固定 y 需要满足 $0<y<2x$ 且 $x<1$, 等价于 $x>y/2$ 且 $x<1$. 因而 $0<y<2$

$$f_Y(y)=\int_{-\infty}^\infty f_{X,Y}(x,y)dx=\int_{y/2}^1 1dx=1-\frac{y}{2},\quad 0<y<2$$

否则 $f_Y(y)=0$.

(b) 由于 X 是一个 continuous random variable, $\mathbb{P}(X = 1/2) = 0$.
$\mathbb{P}(X + Y \leq 3/2)$ 略微难算一点: 满足条件的区域为 $\{(x, y) : 0 < \frac{y}{2} < x < 1, y \leq 3/2 - x\}$,

$$0 < y < \min(2x, 3/2 - x)$$

比较两条上界直线: $2x = 3/2 - x \Rightarrow x = 1/2$ 当 $0 < x < 1/2$, 有 $2x < 3/2 - x$, 所以上界是 $2x$; 当 $1/2 < x < 1$, 上界是 $3/2 - x$.
所以概率等于面积积分:

$$\mathbb{P}(X + Y \leq 3/2) = \int_0^{1/2} \int_0^{2x} 1 dy dx + \int_{1/2}^{1} \int_0^{3/2-x} 1 dy dx$$

计算:

$$\int_0^{1/2} 2x dx = \left[x^2\right]_0^{1/2} = \frac{1}{4}$$

$$\int_{1/2}^{1} \left(\frac{3}{2} - x\right) dx = \left[\frac{3}{2}x - \frac{x^2}{2}\right]_{1/2}^{1} = 1 - \frac{5}{8} = \frac{3}{8}$$

合并得

$$\mathbb{P}(X + Y \leq 3/2) = \frac{1}{4} + \frac{3}{8} = \frac{5}{8}$$

也可以通过画图来做. 我们画出 support set 的图:

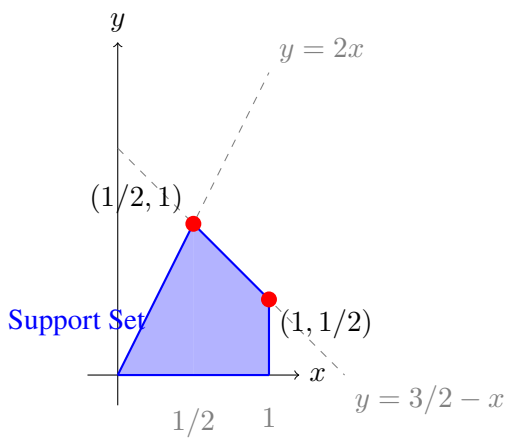

在这个图上对联合函数积分即可.

3.2 independence of two random variables

3.2.1 independence of two random variables 的三种等价定义

Def 3.5 (independence of random variables, def 1: joint distribution is product of marginal distributions)

两个 random variables $X, Y : \Omega \to \mathbb{R}$ 被称为 independent 的, 如果对于任意的 Borel sets $A, B \subseteq \mathbb{R}$, 都有

$$\mathbb{P}(X \in A, Y \in B) = \mathbb{P}(X \in A) \cdot \mathbb{P}(Y \in B)$$

注意这个定义等价于 for all points $(x, y) \in \mathbb{R}^2$,

$$F_{X,Y}(x, y) = F_X(x) F_Y(y)$$

即它们的 **joint distribution** 是它们 **marginal distributions** 的 **product.** ♣

对于 discrete 和 continuous random variables 而言, 这还意味着 independence 等价于:

- joint pmf 是 marginal pmfs 的 product, for discrete case.
- joint pdf 是 marginal pdfs 的 product, for continuous case.

详细而言:

Theorem 3.2 (discrete and continuous independence: joint density is product of marginal densities)

令 X, Y 是两个 random variables.

- 如果 X, Y 是 discrete random variables, 则它们 independent 的条件等价于对于任意 x, y, 都有
$$p_{X,Y}(x, y) = p_X(x) \cdot p_Y(y)$$
- 如果 X, Y 是 continuous random variables, 则它们 independent 的条件等价于对于任意 x, y, 都有
$$f_{X,Y}(x, y) = f_X(x) \cdot f_Y(y)$$

♡

Proof discrete case: 显然可得.

continuous case:

- $F_{X,Y}(x, y) = F_X(x)F_Y(y) \implies f_{X,Y}(x, y) = f_X(x) \cdot f_Y(y)$: 取偏导数即可.
- $f_{X,Y}(x, y) = f_X(x) \cdot f_Y(y) \implies F_{X,Y}(x, y) = F_X(x)F_Y(y)$: 积分即可.

因而对于 independent 的两个 random variables, 固定 $X = x_0$, 那么联合密度函数 $f_{X,Y}(x_0, y)$ 就是 Y 的边际密度函数 $f_Y(y)$ 乘上一个常数 $f_X(x_0)$.

Remark

Recall 两个事件 independence 的定义:

$$\mathbb{P}(A \cap B) = \mathbb{P}(A) \cdot \mathbb{P}(B)$$

也等价于对于任意的 Borel sets A, B where $\mathbb{P}(B) > 0$, 都有

$$\mathbb{P}(A \mid B) = \mathbb{P}(A)$$

即: 一个事件发生与否都不会对另一个事件发生的概率产生任何影响.

而再看到两个 random variables independence 的定义是:

$$\mathbb{P}(X \in A, Y \in B) = \mathbb{P}(X \in A) \cdot \mathbb{P}(Y \in B)$$

这个定义也当然等价于:

Proposition 3.5 (independence of random variables, def 2: conditional distribution is marginal distribution)

两个 random variables X, Y 是 independent 的, iff: 对于任意的 Borel sets A, B, 如果 $\mathbb{P}(Y \in B) > 0$, 则

$$\mathbb{P}(X \in A \mid Y \in B) = \mathbb{P}(X \in A)$$

即: X 的 **conditional distribution, 不论给定** Y **的任何信息, 都等于** X **的 marginal distribution.** ♠

所以它实际上意义是: **知道一个 random variable 的任何信息, 对于另外一个都没有任何帮助.**

因而**它们的 joint distribution 可以分解成 marginal distributions 的 product**.

Remark

Furthermore: 我们不难发现一件事情, 可以**在 independence of two events 和 independence of two random variables 之间建立一个桥梁:**

Proposition 3.6 (independence of random variables, def 3: generated sigma-algebras)

令 X, Y 是两个 random variables. 则 X, Y 是 independent 的 iff: X 生成的 sigma-algebra $\sigma(X)$ 和 Y 生成的 sigma-algebra $\sigma(Y)$ 中分别任取一个事件, 这两个事件都是 independent 的. 即:

$$\forall A \in \sigma(X), \forall B \in \sigma(Y), \quad \mathbb{P}(A \cap B) = \mathbb{P}(A) \cdot \mathbb{P}(B)$$

♠

这严格说明了: **两个 random variables 之间的 independence, 本质上是它们各自蕴含的 information (由 generated sigma-algebra 严格刻画) 的完全不相关**: 对 X 的观测对于预测 Y 的任何行为都不提供任何帮助, 反之亦然.

以上就是 independence of two random variables 的定义, 以及其 information geometric intuition.
下面我们讲 independence between two random variables, generalize 到 mutual independence among 任意的 family of random variables.

3.2.2 mutual independence of a family of random variables: 强于 pairwise independence

我们定义了两个 random variables 的 independence, 但是这个定义可以推广到多个 (甚至 uncountably many) random variables 上.

Def 3.6 (mutual independence of multiple random variables)

令 $\{X_i : i \in I\}$ 是一个 random variables 的 family, 其中 I 是一个 index set. 则如果对于任意的 finite subset $J \subseteq I$, 以及对于任意的 Borel sets $\{A_j : j \in J\}$, 都有

$$\mathbb{P}(X_j \in A_j, \forall j \in J) = \prod_{j \in J} \mathbb{P}(X_j \in A_j)$$

则称这个 family of random variables 是 independent 的.

♣

注意: **joint mass & density 的 factorization 也可以推广到多个 random variables 上.** 有一件事情值得说明: 这里定义的是 **mutual independence**, 也就是说, 对于任意的 finite subset J, 它们的 joint distribution 都 factorizes into product of marginal distributions.
而**两两 independent 的 random variables family 不一定是 mutual independent 的.** 即: 如果对于任意的 $i \neq j$, X_i 和 X_j 是 independent 的, 并不意味着对于任意的 finite subset J, $\{X_j : j \in J\}$ 是 independent 的.
举个例子:

Example 3.3 pairwise independence does NOT imply mutual independence 假设我们抛掷两枚公平的硬币. 令 X, Y 是两个 independent 的 random variables, 且都服从 uniform distribution on $\{-1, 1\}$. 即:

$$\mathbb{P}(X = 1) = \mathbb{P}(X = -1) = \frac{1}{2}, \quad \mathbb{P}(Y = 1) = \mathbb{P}(Y = -1) = \frac{1}{2}$$

现在, 我们定义第三个 random variable Z 为前两者的 product:

$$Z = X \cdot Y$$

容易验证: X, Y, Z 两两 independent, 但不 mutual independent. 因为如果只是知道 X 的值, 那么我们对于 Z 的值完全没有信息 (因为有一个完全随机的 Y 没有任何已知信息); 同样, 如果只是知道 Y 的值, 那么我们对于 Z 的值也完全没有信息;
但是, 如果我们同时知道 X 和 Y 的值, 那么 Z 的值就完全确定了.
这说明 **pairwise independence 只能保证局部的信息解耦, 而 mutual independence 则保证了在这个 family of random variables 之间的全局信息解耦.**

3.2.3 independent $\implies$ uncorrelated

Independence 的概念会让我们回忆起另外一个刻画两个 random variables 之间关系的概念: covariance, 它丈量了**两个 random variables 之间的线性关系**.
covariance 的定义:

$$\mathrm{Cov}(X, Y) := \mathbb{E}[(X - \mathbb{E}[X])(Y - \mathbb{E}[Y])] = \mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y]$$

我们容易发现: **independence 是一个比 covariance 为 0 (即 uncorrelated) 更强的概念:**

Proposition 3.7 (independent 严格强于 uncorrelated)

令 X, Y 是两个 random variables. 则 X, Y 是 independent 的 $\implies$ $\mathrm{Cov}(X, Y) = 0$. 但是 $\mathrm{Cov}(X, Y) = 0$ 不一定 $\implies$ X, Y 是 independent 的. ♠

Proof

- independence $\implies$ covariance 是 0, 因为 independence 显然 imply$E[XY] = E[X]E[Y]$, 从而 covariance 的定义式中 $E[XY] - E[X]E[Y] = 0$.
- 有一个经典反例: 考虑 X 是任意按原点对称的分布, 比如一个 standard normal distribution; 而定义 $Y = X^2$, 此时

  $$\mathrm{Cov}(X, X^2) = E[X \cdot X^2] - E[X]E[X^2] = E[X^3] - E[X]E[X^2]$$

  由于 X 的分布是关于原点对称的, $E[X^3] = 0$ 且 $E[X] = 0$, 因而 covariance 是 0. 但是 X 和 Y 显然不是 independent 的.

Remark 本质上, independence 是一种最强的全局信息不相关性. 而 covariance 只度量 linear relationship. 试想: 如果这两个随机变量之间的关系是这样的呢?

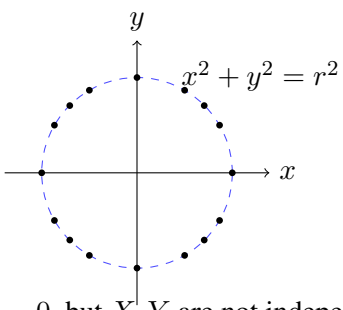

$\mathrm{Cov}(X, Y) = 0$, but X, Y are not independent

那么它们的 covariance 是 0, 但是它们显然不是 independent 的. 所以 covariance 忽略了很多非线性的关系, 而 independence 则完全捕捉了所有的关系.

刚才说到, 两个 random variables 的 independence 显然 imply $\mathbb{E}[XY] = \mathbb{E}[X]\mathbb{E}[Y]$. 而 BTW: 这个性质其实**可以 generalize 到任意 finite number of independent random variables 的 product 上, 并且我们可以在这些 random variables 上任意地施加 Borel measurable functions**, 只要保证这些函数的 expectation 是 finite 的,

Theorem 3.3 (independence $\implies$ expectation is closed under product)

令 $\{X_i : i \in I\}$ 是一个 independent 的 random variables 的 family, 则对于任意的 finite subset $J \subseteq I$, 以及对于任意的 Borel measurable functions $\{g_j : j \in J\}$, 如果 $\mathbb{E}[|g_j(X_j)|] < \infty$ for all $j \in J$, 则

$$\mathbb{E}\left[\prod_{j\in J} g_j(X_j)\right] = \prod_{j\in J} \mathbb{E}[g_j(X_j)]$$

特别地, 取每个 $g_j(x) = x$, 则

$$\mathbb{E}\left[\prod_{j\in J} X_j\right] = \prod_{j\in J} \mathbb{E}[X_j]$$

♡

Proof 令 $J = \{1, 2, \ldots, n\}$. 由于 $X_1, \ldots, X_n$ 是 independent 的, 它们的 joint distribution $\mu_{\mathbf{X}}$ 是其 marginal distributions μ_{X_j} 的 product measure:

$$\mu_{\mathbf{X}} = \mu_{X_1} \times \mu_{X_2} \times \cdots \times \mu_{X_n}$$

根据 Change of Variables Formula,

$$\mathbb{E}\left[\prod_{j=1}^{n} g_j(X_j)\right] = \int_{\mathbb{R}^n} \left(\prod_{j=1}^{n} g_j(x_j)\right) d\mu_{\mathbf{X}}(x_1, \ldots, x_n) = \int_{\mathbb{R}} \cdots \int_{\mathbb{R}} \left(\prod_{j=1}^{n} g_j(x_j)\right) d\mu_{X_1}(x_1) \ldots d\mu_{X_n}(x_n)$$

由于被积函数 $\prod g_j(x_j)$ 是变量分离的, 根据 Fubini's Theorem 可以把积分分解成多个积分的 product:

$$= \left(\int_{\mathbb{R}} g_1(x_1)\, d\mu_{X_1}(x_1)\right) \times \cdots \times \left(\int_{\mathbb{R}} g_n(x_n)\, d\mu_{X_n}(x_n)\right)$$

其中每一项都是 $\mathbb{E}[g_j(X_j)]$.

Remark recall: expectation is a linear operator (因而 linearity 是 regardless of independence). 但是它不一定是一个 multiplicative operator.

而这里我们说, **如果 random variables 是 independent 的, 那么 expectation 就是一个 multiplicative operator.**

实际上: 当这些 Borel measurable functions $\{g_j : j \in J\}$ 全都 bounded 时, 这个定理其实反向也是成立的:

Theorem 3.4

令 $\{X_i : i \in I\}$ 是一个 family of random variables. 如果对于任意的 finite subset $J \subseteq I$, 以及任意的 bounded Borel measurable functions $\{g_j : j \in J\}$, 都有

$$\mathbb{E}\left[\prod_{j\in J} g_j(X_j)\right] = \prod_{j\in J} \mathbb{E}[g_j(X_j)]$$

则这个 family of random variables 是 independent 的.

♡

Proof 不妨特取 indicator functions. 对于任意的 Borel sets $A, B \subseteq \mathbb{R}$, 令 $f(x) = I_A(x)$, $g(y) = I_B(y)$. 代入等式得到:

$$\mathbb{E}[I_A(X) \cdot I_B(Y)] = \mathbb{E}[I_A(X)] \cdot \mathbb{E}[I_B(Y)]$$

注意到 $I_A(X) \cdot I_B(Y) = I_{\{X \in A, Y \in B\}}$. 根据 expectation of indicator function 等于 probability, 我们立刻得到:

$$\mathbb{P}(X \in A, Y \in B) = \mathbb{P}(X \in A) \cdot \mathbb{P}(Y \in B)$$

注意: $g(x) = x$ **并不是 bounded 的 function, 因而 uncorrelation $\not\Longrightarrow$ independence.**

OK. 以上是 pretty much general properties of independence. 最后我们看一下, 对于 discrete 和 continuous random variables 而言, independence 的 characterization 具体长什么样子.

3.2.4 discrete RV independence 的 characterization

Remark 关于两个 discrete random variables X, Y 是否 independent 的判断, 还有一个直观的方法.

Proposition 3.8 (discrete RV independence 的 characterization)

两个 discrete random variables X, Y 是 independent 的 iff 它们的 joint pmf as a matrix 有 rank 1(每行每列都互为倍数).

Proof note: 一个矩阵 M 的 rank 等于 1 iff 它可以被分解为两个向量的 outer product :

$$M = \mathbf{u}\mathbf{v}^\top$$

where $\mathbf{u}$ 和 $\mathbf{v}$ 是非零列向量.

($\Longrightarrow$): 如果 independent, 那么对于所有 i, j, joint probability $p_{ij} = \mathbb{P}(X = x_i, Y = y_j)$ 满足:

$$p_{ij} = \mathbb{P}(X = x_i) \cdot \mathbb{P}(Y = y_j)$$

如果我们定义向量 $\mathbf{p}_X = [p_X(x_1), p_X(x_2), \dots]^\top$ 和 $\mathbf{p}_Y = [p_Y(y_1), p_Y(y_2), \dots]^\top$, 那么整个联合分布矩阵 P 就可以写成:

$$P = \mathbf{p}_X \mathbf{p}_Y^\top$$

这正是 Rank 1 矩阵的标准形式.

($\Longleftarrow$) 如果 P 的 rank 为 1, 那么存在向量 $\mathbf{u}$ 和 $\mathbf{v}$ 使得 $p_{ij} = u_i v_j$. 由于 $\sum_{i,j} p_{ij} = 1$, 我们可以归一化这两个向量, 使得 $\sum u_i = 1$ 且 $\sum v_j = 1$. 此时, u_i 恰好就是 X 的 marginal PMF, v_j 恰好就是 Y 的 marginal PMF. 因此满足 $p_{ij} = p_i \cdot p_j$, 即两个变量独立.

Example 3.4

$P =$

$X \backslash Y$	0	1	Marginal $\mathbb{P}(X)$
0	0.4	0.1	0.5
1	0.4	0.1	0.5
Marginal $\mathbb{P}(Y)$	0.8	0.2	1.0

这里的 X, Y 就是 independent 的 random variables.

3.2.5 continuous RV independence 的 geometric intuition

对于 independent continuous random variables X, Y, 它的 characterization 我们已经知道了: 即 joint pdf factorizes into marginal pdfs. 这一个 characterization 的 geometric intuition 是:

- joint pdf 的 support set 一定是一个矩形 (不一定 bounded)
- joint pdf 的**每个维度上的任意截面的形状都是一样的** (因为固定 x, 则 y 方向的性质只由 f_Y 决定.) 即: 固定 x, y-distribution 的横截面永远长得像 f_Y, 只是乘上了一个常数 $f_X(x)$ 而已. 同样的, 固定 y, x 分布的横截面永远长得像 f_X, 只是乘上了一个常数 $f_Y(y)$ 而已.

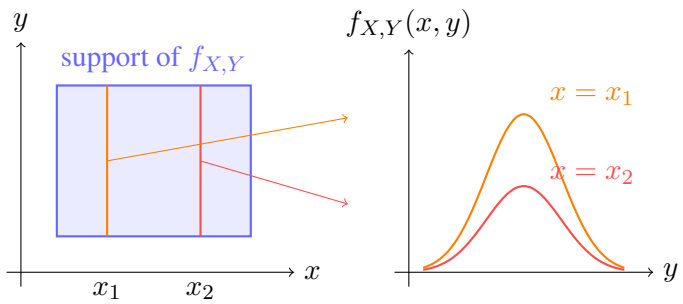

same shape, only different scale

3.3 conditional distribution function and density

3.3.1 conditional distribution and its distribution function

Def 3.7 (conditional distribution)

给定 random variables $X, Y : \Omega \to \mathbb{R}$, 我们定义 the conditional distribution of X given $Y = y$ 为 the probability measure $\mathbb{P}^{X|Y=y}$:

$$\mathbb{P}^{X|Y=y}(A) := \lim_{h\to 0^+} \mathbb{P}(X \in A \mid y \le Y \le y+h), \quad \forall A \in \mathcal{B}(\mathbb{R})$$

并将 function $F_{X|Y=y} : \mathbb{R} \to \mathbb{R}$ defined by $F_{X|Y=y}(x) := \mathbb{P}^{X|Y=y}((-\infty, x])$:

$$F_{X|Y}(x|y) := \lim_{h\to 0^+} \mathbb{P}(X \le x \mid y \le Y \le y+h)$$

称为 the conditional distribution function of X given $Y = y$. ♣

Remark 注意: 每个取值 y 都对应一个 conditional distribution measure $\mathbb{P}^{X|Y=y}$ 和一个 conditional distribution function $F_{X|Y=y}$. 因此, conditional distribution 和 conditional distribution function 都是一个 family of measures/functions, 而不是一个 measure/function.

也就是说, 一个 random variable 可以 induce 出另一个 random variable 的可能 uncountably many 个 conditional distribution.

Remark 如果 X, Y 是两个 discrete random variables, 那么它们的 conditional distribution 就很简单了.

$$\mathbb{P}^{X|Y=y}(\{x\}) = \frac{\mathbb{P}(X = x, Y = y)}{\mathbb{P}(Y = y)}$$

以及

$$F_{X|Y=y}(x) = \sum_{t \le x} \frac{\mathbb{P}(X = t, Y = y)}{\mathbb{P}(Y = y)}$$

其他情况稍复杂一些. 但是我们可以确定的是:

3.3.2 conditional density for random variables jointly continuous

Theorem 3.5 (jointly continuous RVs 之间所有 defined 处总有 conditional density)

令 $\mathbf{X} = (X, Y)^T$ 是一个 continuous random vector, 则对于任意 y 使得 $f_Y(y) > 0$, 都有 conditional distribution of X given $Y = y$ 的 pdf:

$$f_{X|Y}(x|y) := \frac{f_{X,Y}(x,y)}{f_Y(y)}$$

即: $\forall x \in \mathbb{R}$ 有:

$$F_{X|Y}(x|y) = \int_{-\infty}^{x} \frac{f_{X,Y}(t,y)}{f_Y(y)}\, dt$$

♡

Proof 注意: $(X, Y)^T$ 是 continuous random vector $\implies$ Y 是一个 continuous random variable. 因而因而 $f_Y(y)$ 是 well-defined 的. (反过来不成立) 取 y s.t. $f_Y(y) > 0$.
则

$$\begin{aligned}
\mathbb{P}^{X|Y=y}(A) &= \lim_{h\to 0^+} \mathbb{P}(X \in A \mid y \le Y \le y+h) \\
&= \lim_{h\to 0^+} \frac{\mathbb{P}(X \le x, y \le Y \le y+h)}{\mathbb{P}(y \le Y \le y+h)} = \lim_{h\to 0^+} \frac{F_{X,Y}(x, y+h) - F_{X,Y}(x,y)}{F_Y(y+h) - F_Y(y)} \\
&= \frac{\partial_y F_{X,Y}(x,y)}{f_Y(y)} = \int_{-\infty}^{x} \frac{f_{X,Y}(s,y)}{f_Y(y)} ds
\end{aligned}$$

因而, $f_{X|Y}(x|y) := \frac{f_{X,Y}(x,y)}{f_Y(y)}$ 是 $F_{X|Y=y}$ 的 pdf.

Remark 为了保证 continuous random vector 下分量之间的 conditional distribution 总是 (a.e.) 拥有 pdf 的, 我们可以给 not well-defined 处下定义: 如果 $f_Y(y) = 0$, 就直接 set $f_{X|Y}(x|y) = 0$ for all x.
在这个定义下: continuous random vector 下分量之间的 conditional distribution 也总是 continuous 的.

3.3.3 Law of Total Probability for continuous random vector

Theorem 3.6

令 $\mathbf{X} = (X, Y)^T$ 是一个 continuous random vector, 则对于任意 $A \in \mathcal{B}(\mathbb{R})$,

$$\mathbb{P}((X,Y) \in A) = \int_{-\infty}^{+\infty} \mathbb{P}((X,y) \in A \mid Y = y) f_Y(y) dy$$

♡

Proof 注意:

$$\mathbb{P}\left(Y \in \{y \in \mathbb{R} : f_Y(y) = 0\}\right) = 0$$

即, $\left\{Y \in f_Y^{-1}(\{0\})\right\}$ 是一个 null set. (不是说 $f_Y(y) = 0$ 的 y 是 null set, 意思是说 Y 落在这些 y 上的事件是 null set.)

因而 compute:

$$\begin{aligned}
\mathbb{P}(X \in (-\infty, x], Y \le y) &= \mathbb{P}\left(X \in (-\infty, x], \{Y \le y\} \cap \left\{Y \notin f_Y^{-1}(\{0\})\right\}\right) = \int_{(-\infty,y]\cap f_Y^{-1}(\{0\}^c)} \int_{-\infty}^{\infty} f_{X,Y}(s,t)dsdt \\
&= \int_{(-\infty,y]\cap f_Y^{-1}((0,+\infty))} \left(\int_{-\infty}^{x} \frac{f_{X,Y}(s,t)}{f_Y(t)} ds\right) f_Y(t)dt \\
&= \int_{(-\infty,y]\cap f_Y^{-1}((0,+\infty))} \mathbb{P}(X \le x \mid Y = t) f_Y(t)dt \\
&= \int_{(-\infty,y]\cap f_Y^{-1}((0,+\infty))} \mathbb{P}(X \le x \mid Y = t) f_Y(t)dt + \int_{(-\infty,y]\cap f_Y^{-1}(\{0\})} \mathbb{P}(X \le x \mid Y = t) f_Y \\
&= \int_{(-\infty,y]} \mathbb{P}(X \le x \mid Y = t) f_Y(t)dt \\
&= \int_{-\infty}^{y} \mathbb{P}(X \le x \mid Y = t) f_Y(t)dt
\end{aligned}$$

Remark recall 最普通的全概率公式: 把样本空间 partition 成几个 disjoint 的事件 $B_1, \cdots, B_n$, 则任意事件 A 等于它在每个 B_i 上的 conditional probability 的和:

$$\mathbb{P}(A) = \sum_{i=1}^{n} \mathbb{P}(A \cap B_i) = \sum_{i=1}^{n} \mathbb{P}(A \mid B_i)\mathbb{P}(B_i)$$

这很容易理解. 而这里的 law of total probability for continuous random vector 就是这个公式在 continuous case 的推广:

由于在每一点 y 上, $(X,Y) \in A$ 的概率都有一个 conditional distribution $(X,Y) \in A | Y = y$, 因而 $(X,Y) \in A$ 的概率就等于这个 conditional distribution 在所有 y 上的加权和, 权重就是 Y 的 pdf $f_Y(y)$. 因而才有

$$\mathbb{P}((X,Y) \in A) = \int_{-\infty}^{+\infty} \mathbb{P}((X,y) \in A \mid Y = y) f_Y(y)dy$$

Example 3.5 考虑 random vector $\mathbf{X} = (X,Y)^T$ with joint pdf

$$f_{X,Y}(x,y) = \begin{cases} 4xy, & \text{if } 0 \le x \le 1, 0 \le y \le 1 \\ 0, & \text{otherwise} \end{cases}$$

计算: $f_X, f_Y, f_{X|Y}, f_{Y|X}$.

Sol. 首先计算 margianl pdfs:

$$f_X(x) = \int_{-\infty}^{+\infty} f_{X,Y}(x,y)dy = \int_0^1 4xydy = 2x, \text{ for } 0 \le x \le 1$$

and

$$f_Y(y) = \int_{-\infty}^{+\infty} f_{X,Y}(x,y)dx = \int_0^1 4xydx = 2y, \text{ for } 0 \le y \le 1$$

由于这是一个 continuous random vector, 因而根据 3.5 可以得到:

$$f_{X|Y}(x \mid y) = \begin{cases} \frac{f_{X,Y}(x,y)}{f_Y(y)} = \frac{4xy}{2y} = 2x, & \text{if } x \in [0,1], \\ 0, & \text{otherwise.} \end{cases}$$

同理计算出

$$f_{Y|X}(y \mid x) = \begin{cases} \frac{f_{X,Y}(x,y)}{f_X(x)} = \frac{4xy}{2x} = 2y, & \text{if } y \in [0,1], \\ 0, & \text{otherwise.} \end{cases}$$

3.4 conditional expectation

Def 3.8 (conditional expectation)

令 $X, Y : \Omega \to \mathbb{R}$ 为 RVs. 对于 $y \in \mathbb{R}$ where $F_{X|Y} = \mathbb{P}^{X|Y=y}(X \leq x)$ is defined (这个条件对于 discrete 是筛选掉 $\mathbb{P}(y) = 0$ 的点, 对于 continuous 这是为了筛选掉 $f_Y = 0$ 的点), 我们定义 conditional expectation:

$$\mathbb{E}[X|Y = y] := \int_{-\infty}^{\infty} x \, d\mathbb{P}^{X|Y=y}(x)$$

特别地, 如果 (X, Y) 是一个 discrete random vector, 则它即是:

$$\mathbb{E}[X|Y = y] = \sum_x x\mathbb{P}(X|Y)(x|y) = \sum_x x\mathbb{P}(X = x|Y = y)$$

而如果 (X, Y) 是一个 (absolutely) continuous random vector, 则它即是:

$$\mathbb{E}[X|Y = y] = \int_{-\infty}^{\infty} x f_{X|Y}(x|y) \, dx$$

♣

Remark 注意: conditional expectation 对于给定的 y 是一个值; 而它也整体是一个 function of y, 同时也是 function from the sample space Ω (更准确而言是 $\{\omega \in \Omega : f_Y(Y(\omega)) > 0\}$, 但是去掉的这个集合的测度为零, 所以不用管, a.e. define 即可).
对于 $\omega \in \Omega$,

$$\mathbb{E}[X|Y] : \omega \mapsto \mathbb{E}[X|Y = Y(\omega)]$$

Notice: 这个函数是一个 random variable. 同理, 我们可以构造 conditional expectation given multiple random variables $\mathbb{E}[X|Y_1, \cdots, Y_n]$. 但是暂时不谈论这个.

Proposition 3.9 (independence 让 conditional distribution, density 和 expectation 都退化)

如果 X, Y 是 independent 的, 那么在任意 defined y 上,

$$F_{X|Y=y} = F_X, \quad f_{X|Y=y} = f_X,$$

以及

$$\mathbb{E}[X|Y] = \mathbb{E}[X]$$

♠

Example 3.6 (constant random variable 的 conditional expectation)
令 $X := b$ 为一个 constant random variable. Y 为一个 (absolutely) continuous random variable. compute: $\mathbb{E}[X|Y]$ when $f_Y(y) > 0$.
Sol.

$$F_{X,Y}(x, y) = \mathbb{P}(X \leq x, Y \leq y) = \begin{cases} F_Y(y), & \text{if } x \leq b, \\ 0, & \text{if } x > b \end{cases} = F_X(x) \cdot F_Y(y)$$

因而它们 independent (当然,,) 因而

$$\mathbb{E}[X|Y] = \mathbb{E}[X] = b$$

为什么我们要提及这个很呆的例子因为我们要说一个很呆但是要说一下的事情:

Proposition 3.10

conditional expectation 满足 linear property. 即任取 $a, b \in \mathbb{R}$,

$$\mathbb{E}[aX + b|Y] = a\mathbb{E}[X|Y] + b$$

♠

Example 3.7 (computation exercise) 令 X, Y 为 RVs with joint pdf

$$f_{X,Y}(x, y) = \begin{cases} \frac{1}{y}e^{-\frac{x}{y}}e^{-y}, & x > 0, y > 0 \\ 0, & \text{otherwise} \end{cases}$$

计算: $\mathbb{E}[X|Y = y]$.

Sol. 根据 3.5 和 3.8, 我们就是要做两件事情: 一个是计算 f_Y, 然后根据 f_Y 和 $f_{X,Y}$ 计算出 $f_{X|Y}$, 最后根据 $f_{X|Y}$ 积分计算出 $\mathbb{E}[X|Y]$.

那么

$$f_Y(y) = \int_{-\infty}^{+\infty} f_{X,Y}(x, y)dx = e^{-y}\int_0^{+\infty} \frac{1}{y}e^{-x/y}dx = e^{-y}, y > 0$$

我们发现 $Y \sim \text{Exp}(1)$. 然后对于 $y > 0$,

$$f_{X|Y}(x \mid y) = \frac{f_{X,Y}(x, y)}{f_Y(y)} = \frac{1}{y}e^{-x/y}$$

因而 $X|Y = y \sim \text{Exp}(1/y)$. 最后,

$$\mathbb{E}[X \mid Y = y] = \int_{-\infty}^{+\infty} x f_{X|Y}(x \mid y)dx = \frac{1}{y}\int_0^{+\infty} xe^{-x/y}dx = y$$

而对于 $y \leq 0$, 因为 $f_Y(y) = 0$, $\mathbb{E}[X \mid Y = y]$ is not defined.

//TODO: 如果 X 是 continous 的, 而 Y 是 discrete 的, 那么我们怎么 define conditional distribution, 以及 expectation 呢? 这个时候我们就需要用到之前说的 generated σ-algebra 的概念了.

3.5 law of total expectation

Theorem 3.7 (law of total expectation)

令 $X, Y : \Omega \to \mathbb{R}$ 为 RVs, 我们知道它们的 conditional expectation $\mathbb{E}[X|Y]$ 也是一个 $\Omega \to \mathbb{R}$ 的 RV. 如果 $\mathbb{E}[|\mathbb{E}[X|Y]|] < \infty$, 则

$$\mathbb{E}[X] = \mathbb{E}[\mathbb{E}[X|Y]]$$

♡

Proof 对于更加严格的 conditional expectation 的定义而言 (as an orthogonal projection from $L^2(\Omega, \mathcal{F}, \mathbb{P})$ onto the subspace of Y-measurable functions), 这个定理是 trivial 的, 直接 follow from def. 在该定义中, $\mathbb{E}[X|Y]$ 被定义为一个 $\sigma(Y)$-measurable function Z, 使得对于任意 $A \in \sigma(Y)$, 都有

$$\int_A Z\, d\mathbb{P} = \int_A X\, d\mathbb{P}$$

那么取 $A = \Omega$, 自然得到.

而我们目前的定义下, 要证明它则要对于 discrete 和 continuous 两种情况分别计算证明. (recall Lebesgue Decomposition Theorem: 任意 measure 都可以被分解成一个 discrete 的部分和一个 continuous 的部分以及一个可以忽略的 singular 的部分. 因而证明了 discrete 和 continuous 两种情况即可.)

For discrete case:

$$\begin{aligned}\mathbb{E}[\mathbb{E}[X \mid Y]] = \mathbb{E}_\omega[\mathbb{E}[X \mid Y = Y(\omega)]] &= \mathbb{E}_\omega\left[\sum_x x\mathbb{P}(X = x \mid Y = Y(\omega))\right] \\ &= \sum_x x\mathbb{E}_\omega[\mathbb{P}(X = x \mid Y = Y(\omega))] \\ &= \sum_x x \sum_y \mathbb{P}(X = x \mid Y = y) \cdot \mathbb{P}(Y = y) \\ &= \sum_x x \sum_y \mathbb{P}(X = x, Y = y) \\ &= \sum_x x\mathbb{P}(X = x) = \mathbb{E}[X]\end{aligned}$$

For continuous case:

$$\begin{aligned}\mathbb{E}[\mathbb{E}[X \mid Y]] = \mathbb{E}_\omega\left[\int_{-\infty}^{+\infty} x f_{X|Y}(x \mid Y(\omega))dx\right] &= \int_{-\infty}^{+\infty} x\mathbb{E}_\omega\left[f_{X|Y}(x \mid Y(\omega))\right]dx \\ &= \int_{-\infty}^{+\infty} x \int_{-\infty}^{+\infty} f_{X|Y}(x \mid y) f_Y(y)dydx \\ &= \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} x f_{X,Y}(x, y)dxdy \\ &= \int_{-\infty}^{+\infty} x \int_{-\infty}^{+\infty} f_{X,Y}(x, y)dxdx \\ &= \int_{-\infty}^{+\infty} x f_X(x)dx = \mathbb{E}[X]\end{aligned}$$

Example 3.8 (**fair coin toss**) 我们投掷一枚 fair coin. X_1: 直到 HH 出现钱, 投掷的次数;
X_2: 直到 HT 出现钱, 投掷的次数.
问题: 计算 $\mathbb{E}[X_1]$ 和 $\mathbb{E}[X_2]$.

Sol. We condition on 第一次 toss Y_1, 以及第二次 toss Y_2.

$$\begin{aligned}\mathbb{E}[X_1] = \mathbb{E}[\mathbb{E}[X_1 \mid Y_1]] &= \frac{1}{2}\mathbb{E}[X_1 \mid Y_1 = H] + \frac{1}{2}\mathbb{E}[X_1 \mid Y_1 = T] \\ &= \frac{1}{2}\left(\frac{1}{2}\mathbb{E}[X \mid Y_1 = H, Y_2 = H] + \frac{1}{2}\mathbb{E}[X \mid Y_1 = H, Y_2 = T]\right) + \frac{1}{2}(1 + \mathbb{E}[X_1]) \\ &= \frac{1}{2}\left(\frac{2}{2} + \frac{1}{2}(\mathbb{E}[X_1] + 2)\right) + \frac{1}{2}(1 + \mathbb{E}[X_1]).\end{aligned}$$

解出 $\mathbb{E}[X_1] = 6$. 同理, 可以解出 $\mathbb{E}[X_2] = 4$.

Example 3.9 一只鸡在一段时间内下 N 个蛋, 其中 $N \sim \text{Pois}(\lambda)$. 每只蛋孵化成小鸡的概率为 p, 互相独立. 令 K 表示孵化成小鸡的蛋的数量, 计算 $K|N, \mathbb{E}[K]$, 以及 K 的 distribution.

Sol. 由题意得

$$\mathbb{P}(K = k|N = n) = \binom{n}{k} p^k (1 - p)^{n-k}$$

因此, $K|N = n \sim \text{Bin}(n, p)$ 因而 $\mathbb{E}[K|N = n] = np$. 由 law of total expectation,

$$\mathbb{E}[K] = \mathbb{E}[\mathbb{E}[K|N]] = \mathbb{E}[N] \cdot p = \lambda$$

然后由 law of total probability,

$$\begin{aligned}
\mathbb{P}(K=k) &= \sum_{n=k}^{+\infty} \mathbb{P}(K=k, N=n) = \sum_{n=k}^{+\infty} \mathbb{P}(K=k|N=n)\cdot\mathbb{P}(N=n) \\
&= \sum_{n=k}^{+\infty} \binom{n}{k} p^k (1-p)^{n-k} \cdot \frac{\lambda^n e^{-\lambda}}{n!} \\
&= \sum_{n=k}^{+\infty} \frac{n!}{k!(n-k)!} p^k (1-p)^{n-k} \cdot \frac{\lambda^n e^{-\lambda}}{n!} \\
&= \sum_{n=k}^{+\infty} \frac{\lambda^n e^{-\lambda}}{k!(n-k)!} p^k (1-p)^{n-k} \\
&= \sum_{n=k}^{+\infty} \frac{(\lambda p)^k (\lambda(1-p))^{n-k} e^{-\lambda}}{k!(n-k)!} \\
&= \frac{(\lambda p)^k e^{-\lambda}}{k!} \sum_{n=k}^{+\infty} \frac{(\lambda(1-p))^{n-k}}{(n-k)!} \\
&= \frac{(\lambda p)^k e^{-\lambda}}{k!} \sum_{m=0}^{+\infty} \frac{(\lambda(1-p))^{m}}{m!} \\
&= \frac{(\lambda p)^k e^{-\lambda}}{k!} \cdot e^{\lambda(1-p)} = \frac{(\lambda p)^k e^{-\lambda p}}{k!}
\end{aligned}$$

因而 $K \sim \text{Pois}(\lambda p)$.

Example 3.10 令 (X, Y) 为一对 continuous RVs with joint pdf:

$$f_{X,Y}(x,y) = 2e^{-(x+2y)}\mathbf{1}_{\{x>0, y>0\}}$$

首先, verify $f_{X,Y}$ is a valid joint pdf, 然后计算 $\mathbb{E}[X|Y=y]$ 和 $\mathbb{E}[X]$.

Sol.

$$\int_0^\infty \int_0^\infty 2e^{-(x+2y)} dx dy = \int_0^\infty 2e^{-2y} \left(\int_0^\infty e^{-x} dx \right) dy = \int_0^\infty 2e^{-2y} dy = 1$$

verify 很简单. 然后我们首先计算 density of Y:

$$f_Y(y) = \int_0^\infty 2e^{-(x+2y)} dx = 2e^{-2y}, \quad y > 0$$

然后计算 conditional density of X given $Y = y$:

$$f_{X|Y}(x \mid y) = \frac{f_{X,Y}(x,y)}{f_Y(y)} = e^{-x}, \quad x > 0$$

因而 by 3.8,

$$\mathbb{E}[X \mid Y = y] = \int_0^\infty x e^{-x} dx = 1$$

然后 by law of total expectation,

$$\mathbb{E}[X] = \mathbb{E}[\mathbb{E}[X|Y]] = \mathbb{E}[1] = 1$$

since $\mathbb{E}[X|Y]$ is a constant function.