

Module 4 Behaviors of a sequence of random variables

4.1 Toolbox review: inequalities in probability

这一节是一个 review, 复习一些在 measure theory 中我们已经证明过, 在 probability theory 中经常用到的 inequalities.

4.1.1 Markov's inequality and Chebyshev's inequality

Theorem 4.1 (Markov's inequality)


对于一个 non-negative random variable X (即 $X \geq 0$ a.s.), 任取 $t > 0$, 都有

$$\mathbb{P}(X \geq t) \leq \frac{\mathbb{E}[X]}{t}$$



Remark 这是一个很直观的 geometric intuition: 如果 t 是均值 μ 的 3 倍, 那么 X 大于 t 的测度就不应该超过均值 μ 的 $1/3$; 否则, X 的均值就一定大于 μ 了 (即便其他地方的值都为 0).

它 imply 这样一个时期: 对于 density function, 只要我们知道这个 RV 的均值, 那么对于 density function 截取任意点后面的 tail, 我们总是能够给出一个 upper bound:



Proof 我们考虑一个 indicator function $\mathbf{1}_{\{X \geq t\}}$, 这也是一个 non-negative random variable. 显然:

$$X \geq t \cdot \mathbf{1}_{\{X \geq t\}}$$

(在 $X \geq t$ 的事件上等于, 其他事件上小于), 并且这个 indicator function 的 expectation 正是 X 大于 t 的概率 $\mathbb{P}(X \geq t)$.

因而 by linearity of expectation,

$$\mathbb{E}[X] \geq t\mathbb{E}[\mathbf{1}_{\{X \geq t\}}] = t\mathbb{P}(X \geq t)$$

其值为 1 当 $X \geq t$ 时, 否则为 0. 对于任意的 $t > 0$, 有

□

Corollary 4.1 (Chebyshev's inequality)

对于一个 random variable X 和任意的 $t > 0$, 如果它的方差 $\text{Var}(X)$ 是有限的, 那么有

$$\mathbb{P}(|X - \mathbb{E}[X]| \geq t) \leq \frac{\text{Var}(X)}{t^2}$$



Remark Markov's ineq 是通过均值来 bound 非负随机变量达到一定大小的概率 (在多少事件上是大于 t 的);

Chebyshev's ineq 则是通过方差来 bound 任意随机变量偏离均值达到一定程度的概率 (在多少事件上是偏离均值超过 t 的).

Proof 考虑 non-negative random variable $(X - \mathbb{E}[X])^2$, 那么

$$\mathbb{P}(|X - \mathbb{E}[X]| \geq t) = \mathbb{P}((X - \mathbb{E}[X])^2 \geq t^2) \leq \frac{\mathbb{E}[(X - \mathbb{E}[X])^2]}{t^2} = \frac{\text{Var}(X)}{t^2}$$

□

4.1.2 Cauchy-Schwarz and Jensen's ineq

Theorem 4.2 (Cauchy-Schwarz inequality)

对于任意的 random variables X 和 Y , 都有

$$|\mathbb{E}[XY]| \leq \sqrt{\mathbb{E}[X^2] \cdot \mathbb{E}[Y^2]}$$



这是 prob space 作为一个 measure space, 其上的函数空间 $L^2(\Omega, \mathcal{F}, \mathbb{P})$ 作为一个 Hilbert space, 自然的 Cauchy-Schwarz inequality. 不赘述了.

Theorem 4.3 (Jensen's inequality)

对于一个 convex function ϕ 和任意的 random variable X , 只要 $\mathbb{E}[X]$ 和 $\mathbb{E}[\phi(X)]$ 都是 well-defined 的 (即 finite), 都有

$$\phi(\mathbb{E}[X]) \leq \mathbb{E}[\phi(X)]$$



Proof Let $x_0 := \mathbb{E}[X]$.

Since ϕ is convex, for any x , there exists a supporting line to the graph of ϕ at x . 即存在一个 $m \in \mathbb{R}$ s.t. 对于任意的 y , 都有

$$\phi(x) \geq \phi(x_0) + m(x - x_0)$$

因而 apply to X , 我们 a.s. 有

$$\phi(X) \geq \phi(\mathbb{E}[X]) + m(X - \mathbb{E}[X])$$

因此 by linearity of expectation,

$$\mathbb{E}[\phi(X)] \geq \phi(\mathbb{E}[X]) + m(\mathbb{E}[X] - \mathbb{E}[X]) = \phi(\mathbb{E}[X])$$

□

4.1.3 Fatou's Lemma, MCT and DCT

我们在 measure theory 中最熟悉的三个定理. 复习一下. 这里不 prove 了. proof 请左转 measure theory notes.

Theorem 4.4 (Fatou's Lemma)

令 $\{X_n\}$ 是一列 non-negative random variables, 那么

$$\mathbb{E}[\liminf_{n \rightarrow \infty} X_n] \leq \liminf_{n \rightarrow \infty} \mathbb{E}[X_n]$$



Remark pointwise 下极限的积分, 得到的结果不会大于每个函数积分的下极限.

因为 pointwise 下极限即: 在每个 ω 上, 整个序列中最终稳定的最低水平, 这是最稳定的一层.

而逐个函数可能会有一些 spike, 使得它的 expectation 很大, 但是这个 spike 只出现有限次, 导致 pointwise limitinf 的函数没有受到它的影响; 但是, 不同的 spike 可能 finitely 出现在不同的位置上, 而这个出现的行为是无限的 (比如 typewriter 函数), 使得每个函数的 expectation 都很大, 从而导致 expectation 的 limit 很大.

而 pointwise liminf 的 expectation 就是对每个点都取最终稳定的最低水平, 从而避免了这些 spikes 的影响.

Theorem 4.5 (Monotone Convergence Theorem (MCT))

令 $\{X_n\}$ 是一列递增的 non-negative random variables (即 $X_n \uparrow X$ a.s.), 那么 suppose $X := \lim_{n \rightarrow \infty} X_n$ a.e. exists, 那么 a.s. 有

$$\lim_{n \rightarrow \infty} \mathbb{E}[X_n] = \mathbb{E}[X]$$



Remark 如果 X_n 是递减的, 那么 expectation 的 limit 就等于逐点 limit 的 expectation 了.

Theorem 4.6 (Dominated Convergence Theorem (DCT))

令 $\{X_n\}$ 是一列 random variables, 并且存在一个 a.e. pointwise limit X (即 $X_n \rightarrow X$ a.s.), 并且存在一个 integrable random variable Y 作为一个 bound: 使得 $|X_n| \leq Y$ a.s. 对所有的 n 成立, 那么

$$\lim_{n \rightarrow \infty} \mathbb{E}[X_n] = \mathbb{E}[X]$$



Remark 只要这个序列有一个 integrable 的 uniform bound (不要有很多 unbounded 的 spike 就行了), 那么 expectation 的 limit 就等于逐点 limit 的 expectation 了.

4.1.4 Tonelli and Fubini**Theorem 4.7 (Tonelli's Theorem)**

对于一列 non-negative random variables $\{X_n\}$, 累加和积分 (求期望) 的顺序可以交换:

$$\mathbb{E} \left[\sum_{n=1}^{+\infty} X_n \right] = \sum_{n=1}^{+\infty} \mathbb{E}[X_n]$$

**Theorem 4.8 (Fubini's Theorem)**

对于一列任意的 random variables $\{X_n\}$, 只要其绝对值的 sum 的 expectation 是 finite 的 (或者绝对值的 expectation 的 sum 是 finite 的, by Tonelli 都是一样的), 那么就有 linearity of expectation 的

推广:

$$\mathbb{E} \left[\sum_{n=1}^{+\infty} X_n \right] = \sum_{n=1}^{+\infty} \mathbb{E}[X_n]$$



Remark Fubini 和 Tonelli 即: 把 linearity of expectation 推广到 countable sum 的情况, 前提是 either 非负 (因而无穷不用管) or 它们的 expectation 是一个绝对收敛的 series 就行了.

4.2 Definition review: modes of convergence

这一个 section 也是一个 review. 讲讲不同的 convergence mode 的定义, 以及它们之间的关系.

首先, 我们对 pointwise limit 和 uniform limit 的定义已经很熟悉了, 这里就不赘述了. (算了 uniform 还是提一嘴, 意思是我们需要 pointwise limit 的收敛速度也是 uniform 的, 即对任意的 $\epsilon > 0$, 都存在一个 N 使得对于所有的 $n \geq N$ 和所有的 ω , 都有 $|X_n(\omega) - X(\omega)| < \epsilon$, 是一个严格强于 pointwise 的收敛方式.)

Def 4.1 (RV 序列的三种收敛方式)

- **converge a.s. (almost surely)** 或称 converge with probability 1:

$$\mathbb{P} \left(\lim_{n \rightarrow \infty} X_n = X \right) = 1$$

即:

$$\mathbb{P} \left(\left\{ \omega \in \Omega : \lim_{n \rightarrow \infty} X_n(\omega) = X(\omega) \right\} \right) = 1$$

也就是说 X_n 的 a.e. pointwise limit 是 X .

- **converge in L^p** : 对于 L^p -integrable 的 random variables sequence X_n 和 X , 我们称 $X_n \xrightarrow{L^p} X$, 如果

$$\lim_{n \rightarrow \infty} \mathbb{E}[|X_n - X|^p] = 0$$

即: 这个 seq of RVs 与这个 limit function 之间的 L^p distance 收敛到 0; 也就是它们的偏差 as a random variable, 其 p -th moment 收敛到 0.

- **converge in probability**: 对于任意的 $\epsilon > 0$, 如果

$$\lim_{n \rightarrow \infty} \mathbb{P}(|X_n - X| > \epsilon) = 0$$

即 X_n 与 X 之间的偏差超过 ϵ 的概率收敛到 0.



4.3 Borel-Cantelli Lemma

4.4 Laws of Large Numbers

4.4.1 weak and strong LLN

下面是概率论中最重要的定律之一: 大数定律 (Laws of Large Numbers, LLN).

它证明的是一个十分符合直觉的结论: 一个 random variable 的 sample mean (即 n 个 i.i.d. 的 copy 的均值), 随着 sample 数量的增加, 会 converge to 它的 expectation.

就是说：我们重复做一个相同的实验并取结果的平均值，当我们做的实验足够多时，这个平均值就会非常接近于这个实验的 expectation，也就是理论的均值。

例如最经典的例子就是抛硬币：我们连续抛 n 次一个公平的硬币，记录每次抛出正面（记为 1）或者反面（记为 0），然后计算这些结果的平均值，随着 n 的增加，这个平均值会趋近于 0.5，等于理论的 expectation（这是个 Bernouli random variable, expectation = p ）。

LLN 有两个阶段，weak LLN 和 strong LLN，weak LLN 证明的是这个 convergence 是 in probability 的，而 strong LLN 证明的是这个 convergence 是 a.s. 的。就是说 strong LLN 是严格强于 weak LLN 的。

Theorem 4.9 (weak Law of Large Numbers)

对于一系列 i.i.d. 的 random variables $\{X_i\}$ ，只要这个 random variable 的 expectation 是 finite 的 $\mathbb{E}[X_1^2] < \infty$ ，那么就有：

$$\frac{X_1 + X_2 + \cdots + X_n}{n} \xrightarrow{p} \mathbb{E}[X_1] \quad \text{as } n \rightarrow \infty$$



Proof 简写 $\mu := \mathbb{E}[X_1]$, $S_n := \frac{X_1 + X_2 + \cdots + X_n}{n}$ for each n .

Let $\varepsilon > 0$. It suffices to show: $\mathbb{P}(|S_n - \mu| > \varepsilon) \rightarrow 0$ as $n \rightarrow \infty$. By Chebyshev's inequality, we have

$$\begin{aligned} \mathbb{P}(|S_n/n - \mu| > \varepsilon) &\leq \frac{\text{Var}(S_n/n)}{\varepsilon^2} \\ &= \frac{1}{n^2 \varepsilon^2} \left(\sum_{i=1}^n \mathbb{E}[|X_i - \mu|^2] + 2 \sum_{1 \leq i < j \leq n} \mathbb{E}[(X_i - \mu)(X_j - \mu)] \right) \end{aligned}$$

notice: 由于每个 X_i 都是 i.i.d. 的, independence $\implies$ uncorrelatedness $\implies \text{Cov}(X, Y) = \mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y] = 0$, 因而 $\mathbb{E}[(X_i - \mu)(X_j - \mu)] = \mathbb{E}[(X_i - \mu)]\mathbb{E}[(X_j - \mu)] = 0 \cdot 0 = 0$ for each $i \neq j$.

因而

$$\mathbb{P}(|S_n/n - \mu| > \varepsilon) = \frac{1}{\varepsilon^2 n^2} \sum_{i=1}^n \mathbb{E}[|X_i - \mu|^2] = \frac{1}{\varepsilon^2 n} \cdot n \text{Var}(X_1) \xrightarrow{n \rightarrow \infty} 0$$

□

Theorem 4.10 (strong Law of Large Numbers)

在 weak LLN 4.9 的相同条件（其实可以更弱，让 $\mathbb{E}[X_1] < \infty$ 即可）下，我们其实可以得到一个更强的结论：

$$\frac{X_1 + \cdots + X_n}{n} \xrightarrow{\text{a.s.}} \mathbb{E}[X_1], \quad \text{as } n \rightarrow \infty$$



Proof For simplicity, 我们不证明更弱的条件 ($\mathbb{E}[X_1] < \infty$) 下的 strong LLN 了。只沿用相同的条件。

简写 $\mu := \mathbb{E}[X_1]$, $\sigma^2 := \text{Var}(X_1)$, $S_n := \frac{X_1 + X_2 + \cdots + X_n}{n}$ for each n , 以及

$$Y_n := \frac{S_n}{n} - \mu$$

我们将要证明: $Y_n \xrightarrow{\text{a.s.}} 0$.

首先，在 weak LLN 的 proof 中，我们已经证明了：

$$\mathbb{E}(Y_n) = 0, \quad \mathbb{E}[Y_n^2] = \frac{\sigma^2}{n}$$

我们发现：当我们只采样 n^2 indexed 的时候，它们的 expectation 的 sum 是 finite 的，by p-test (因为 $\sum_{n=1}^{\infty} \frac{1}{n^p}$ 收敛当且仅当 $p > 1$)，即：

$$\mathbb{E} \left[\sum_{n=1}^{+\infty} Y_{n^2}^2 \right] = \sum_{n=1}^{+\infty} \mathbb{E} [Y_{n^2}^2] = \sum_{n=1}^{+\infty} \frac{\sigma^2}{n^2} < \infty$$

先考虑所有 Y_n 都非负的 case. 我们知道：expectation of 一个 non-negative random variable 是 finite 的，就 imply 它是 a.e. finite 的。因而

$$\sum_{n=1}^{+\infty} Y_{n^2}^2 < \infty \quad \text{a.s.}$$

因而

$$\lim_{n \rightarrow \infty} Y_{n^2} = 0 \quad \text{a.s.}$$

意味把在 1, 4, 9, 16... 这些 index 的 Y_i 求 average, 确实收敛到了 μ 。

而我们可以通过 squeeze theorem 得到 general case: 对于任意正整数 k , 总能找到一对平方数把它夹在中间。比如令 $n^2 < k < (n+1)^2$ 。

我们发现：

$$\frac{S_{n^2}}{(n+1)^2} \leq \frac{S_k}{k} \leq \frac{S_{(n+1)^2}}{n^2}$$

notice: $\frac{S_{n^2}}{(n+1)^2} = \frac{S_{n^2}}{n^2} \cdot \frac{n^2}{(n+1)^2}$, 前向 converge to μ , 后向 converge to 1, 因而 $\frac{S_{n^2}}{(n+1)^2} \rightarrow \mu$, 后面那个也同理。因而夹逼得到 $S_k/k \rightarrow \mu$ 。从而得证。

General case:

$$X_n = \max \{X_n, 0\} - \max \{-X_n, 0\} =: X_n^+ - X_n^-$$

因而

$$\frac{X_1 + \dots + X_n}{n} = \frac{X_1^+ + \dots + X_n^+}{n} - \frac{X_1^- + \dots + X_n^-}{n} \xrightarrow{\text{a.s.}} \mathbb{E}[X_1^+] - \mathbb{E}[X_1^-] = \mathbb{E}[X_1]$$

得证。 □

Remark 我们要求 $\mathbb{E}[|X_1|]$ 是 finite 的，或者 $\mathbb{E}[|X_1|^2]$ 是 finite 的，并不是一个硬性的条件，只是结果确实 converge to $\mathbb{E}[X_1]$ 这个 finite value 的条件。

实际上在 $\mathbb{E}[X_1]$ infinite (等于 ∞ 或者 $-\infty$) 时，我们会得到这个 average 发散，因而也是和 $\mathbb{E}[X_1]$ 一样，只不过不是 converge 而是 diverge。

此处不证明了。

4.4.2 application: Monte Carlo methods

任何利用 LLN 来近似计算一个 quantity 的方法，都可以称之为 Monte Carlo 方法。

它的核心思想是：

- 选择一个随机变量，其 expectation 等于我们要计算的 quantity。
- 大量重复采样这个随机变量，并计算样本的平均值
- 根据大数定律，这个平均值近似于我们要计算的 quantity。
- 我们可以用 Chebyshev's inequality 来给出这个近似的误差 bound。

Example 4.1 估算 π 我们令 $X, Y \sim U([-1, 1])$

那么

$$\mathbb{E}[\mathbf{1}_C(X, Y)] = \int_{-1}^1 \int_{-1}^1 \mathbf{1}_C(x, y) f_{X, Y}(x, y) dx dy = \frac{1}{4} \int_{-1}^1 \int_{-1}^1 \mathbf{1}_C(x, y) dx dy = \frac{\pi}{4}$$

注意我们每次随机采样 X, Y 的时候, 都是在 $[-1, 1] \times [-1, 1]$ 这个正方形里随机选一个点, 即创建了一个 random variable (X_i, Y_i) 并进行观测.

根据 LLN, 不论单次的采样结果如何, 我们都可以得到

$$\lim_{n \rightarrow \infty} \frac{\mathbf{1}_C(X_1, Y_1) + \dots + \mathbf{1}_C(X_n, Y_n)}{n} = \frac{\pi}{4}, \quad \text{a.s.}$$

我们还可以用 Chebyshev's inequality 来给出这个近似的误差 bound:

$$\mathbb{P}(|4S_n/n - \pi| > \varepsilon) \leq \frac{\text{Var}(4S_n/n)}{\varepsilon^2} = \frac{4^2}{n^2 \varepsilon^2} \text{Var}\left(\sum_{i=1}^n \mathbf{1}_C(X_i, Y_i)\right) = \frac{16}{n \varepsilon^2} \text{Var}(\mathbf{1}_C(X_1, Y_1)) \approx \frac{1}{n \varepsilon^2}$$

因而当 n 足够大时, 几乎一定可以得到目标值.

```

1 import random
2 def estimate_pi(n):
3     S_n = 0 # This step 1
4     for _ in range(n):
5         # Here is step 2 (and 3)
6         X = random.uniform(-1, 1)
7         Y = random.uniform(-1, 1)
8         # Check if the point is inside the unit circle
9         if X**2 + Y**2 <= 1:
10             S_n += 1
11     pi_estimate = 4 * S_n / n
12     return pi_estimate
13 # Example usage
14 n = 1000000
15 pi_approx = estimate_pi(n)
16 print(pi_approx)

```

4.4.3 application: Bernstein Polynomials

4.4.4 application: Hypothesis testing