# Module 4 Behaviors of a sequence of random variables

## 4.1 Toolbox review: inequalities in probability

这一节是一个 review, 复习一些在 measure theory 中我们已经证明过, 在 probability theory 中经常用到的 inequalities.

### 4.1.1 Markov's ineqaulity and Chebyshev's inequality

**Theorem 4.1 (Markov's inequality)**

对于一个 non-negative random variable $X$ (即 $X \geq 0$ a.s.), 任取 $t > 0$, 都有

$$\mathbb{P}(X \geq t) \leq \frac{\mathbb{E}[X]}{t}$$

♡

**Remark** 这是一个很直观的 geometric intuition: 如果 $t$ 是均值 $\mu$ 的 3 倍, 那么 $X$ 大于 $t$ 的测度就不应该超过均值 $\mu$ 的 1/3; 否则, $X$ 的均值就一定大于 $\mu$ 了 (即便其他地方的值都为 0).
它 imply 这样一个时期: 对于 density function, 只要我们知道这个 RV 的均值, 那么对于 density function 截取任意点后面的 tail, 我们总是能够给出一个 upper bound:

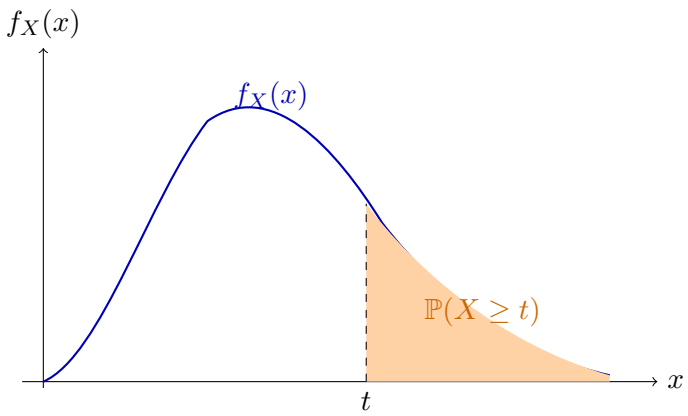


**Proof** 我们考虑一个 indicator function $\mathbf{1}_{\{X \geq t\}}$, 这也是一个 non-negative random variable. 显然:

$$X \geq t \cdot \mathbf{1}_{\{X \geq t\}}$$

(在 $X \geq t$ 的事件上等于, 其他事件上小于), 并且这个 indicator function 的 expectation 正是 $X$ 大于 $t$ 的概率 $\mathbb{P}(X \geq t)$.
因而 by linearity of expectation,

$$\mathbb{E}[X] \geq t\mathbb{E}[\mathbf{1}_{\{X \geq t\}}] = t\mathbb{P}(X \geq t)$$

其值为 1 当 $X \geq t$ 时, 否则为 0. 对于任意的 $t > 0$, 有

**Corollary 4.1 (Chebyshev's inequality)**

对于一个 random variable $X$ 和任意的 $t > 0$, 如果它的方差 $\mathrm{Var}(X)$ 是有限的, 那么有

$$\mathbb{P}(|X - \mathbb{E}[X]| \geq t) \leq \frac{\mathrm{Var}(X)}{t^2}$$

♡

**Remark** Markov's ineq 是通过均值来 bound 非负随机变量达到一定大小的概率 (在多少事件上是大于 $t$ 的);
Chebyshev's ineq 则是通过方差来 bound 任意随机变量偏离均值达到一定程度的概率 (在多少事件上是偏离均值超过 $t$ 的).

**Proof** 考虑 non-negative random variable $(X-\mathbb{E}[X])^2$, 那么

$$\mathbb{P}(|X-\mathbb{E}[X]|\geq t)=\mathbb{P}((X-\mathbb{E}[X])^2\geq t^2)\leq\frac{\mathbb{E}[(X-\mathbb{E}[X])^2]}{t^2}=\frac{\mathrm{Var}(X)}{t^2}$$

### 4.1.2 Cauchy-Schwarz and Jensen's ineq

**Theorem 4.2 (Cauchy-Schwarz inequality)**

对于任意的 random variables $X$ 和 $Y$, 都有

$$|\mathbb{E}[XY]|\leq\sqrt{\mathbb{E}[X^2]\cdot\mathbb{E}[Y^2]}$$

♡

这是 prob space 作为一个 measure space, 其上的函数空间 $L^2(\Omega,\mathcal{F},\mathbb{P})$ 作为一个 Hilbert space, 自然的 Cauchy-Schwarz inequality. 不赘述了.

**Theorem 4.3 (Jensen's inequality)**

对于一个 convex function $\phi$ 和任意的 random variable $X$, 只要 $\mathbb{E}[X]$ 和 $\mathbb{E}[\phi(X)]$ 都是 well-defined 的 (即 finite), 都有

$$\phi(\mathbb{E}[X])\leq\mathbb{E}[\phi(X)]$$

♡

**Proof** Let $x_0:=\mathbb{E}[X]$.
Since $\phi$ is convex, for any $x$, there exists a supporting line to the graph of $\phi$ at $x$. 即存在一个 $m\in\mathbb{R}$ s.t. 对于任意的 $y$, 都有

$$\varphi(x)\geq\varphi(x_0)+m(x-x_0)$$

因而 apply to $X$, 我们 a.s. 有

$$\varphi(X)\geq\varphi(\mathbb{E}[X])+m(X-\mathbb{E}[X])$$

因此 by linearity of expectation,

$$\mathbb{E}[\varphi(X)]\geq\varphi(\mathbb{E}[X])+m(\mathbb{E}[X]-\mathbb{E}[X])=\varphi(\mathbb{E}[X])$$

### 4.1.3 Fatou's Lemma, MCT and DCT

我们在 measure theory 中最熟悉的三个定理. 复习一下. 这里不 prove 了. proof 请左转 measure theory notes.

**Theorem 4.4 (Fatou's Lemma)**

令 $\{X_n\}$ 是一列 non-negative random variables, 那么

$$\mathbb{E}[\liminf_{n\to\infty}X_n]\leq\liminf_{n\to\infty}\mathbb{E}[X_n]$$

♡

**Remark** pointwise 下极限的积分, 得到的结果不会大于每个函数积分的下极限.

因为 pointwise 下极限即: 在每个 $\omega$ 上, 整个序列中最终稳定的最低水平, 这是最稳定的一层.
而逐个函数可能会有一些 spike, 使得它的 expectation 很大, 但是这个 spike 只出现有限次, 导致 pointwise limitinf 的函数没有受到它的影响; 但是, 不同的 spike 可能 finitely 出现在不同的位置上, 而这个出现的行为是无限的 (比如 typewritter 函数), 使得每个函数的 expectation 都很大, 从而导致 expectation 的 limit 很大.
而 pointwise liminf 的 expectation 就是对每个点都取最终稳定的最低水平, 从而避免了这些 spikes 的影响.

**Theorem 4.5 (Monotone Convergence Theorem (MCT))**

令 $\{X_n\}$ 是一列递增的 non-negative random variables (即 $X_n \uparrow X$ a.s.), 那么 suppose $X := \lim_{n\to\infty} X_n$ a.e. exists, 那么 a.s. 有

$$\lim_{n\to\infty} \mathbb{E}[X_n] = \mathbb{E}[X]$$

♡

**Remark** 如果 $X_n$ 是递减的, 那么 expectation 的 limit 就等于逐点 limit 的 expectation 了.

**Theorem 4.6 (Dominated Convergence Theorem (DCT))**

令 $\{X_n\}$ 是一列 random variables, 并且存在一个 a.e. pointwise limit $X$ (即 $X_n \to X$ a.s.), 并且存在一个 integrable random variable $Y$ 作为一个 bound: 使得 $|X_n| \le Y$ a.s. 对所有的 $n$ 成立,
那么

$$\lim_{n\to\infty} \mathbb{E}[X_n] = \mathbb{E}[X]$$

♡

**Remark** 只要这个序列有一个 integrable 的 uniform bound (不要有很多 unbounded 的 spike 就行了), 那么 expectation 的 limit 就等于逐点 limit 的 expectation 了.

### 4.1.4 Tonneli and fubini

**Theorem 4.7 (Tonneli's Theorem)**

对于一列 non-negative random variables $\{X_n\}$, 累加和积分 (求期望) 的顺序可以交换:

$$\mathbb{E}\left[\sum_{n=1}^{+\infty} X_n\right] = \sum_{n=1}^{+\infty} \mathbb{E}\left[X_n\right]$$

♡

**Theorem 4.8 (Fubini's Theorem)**

对于一列任意的 random variables $\{X_n\}$, 只要其绝对值的 sum 的 expectation 是 finite 的 (或者绝对值的 expectation 的 sum 是 finite 的, by Tonneli 都是一样的), 那么就有 linearity of expectation 的推广:

$$\mathbb{E}\left[\sum_{n=1}^{+\infty} X_n\right] = \sum_{n=1}^{+\infty} \mathbb{E}\left[X_n\right]$$

♡

**Remark** Fubini 和 Tonelli 即: 把 linearity of expectation 推广到 countable sum 的情况, 前提是 either 非负 (因而无穷不用管) or 它们的 expectation 是一个绝对收敛的 series 就行了.

## 4.2 Definition review: modes of convergence

这一个 section 也是一个 review. 讲讲不同的 convergence mode 的定义, 以及它们之间的关系.
首先, 我们对 pointwise limit 和 uniform limit 的定义已经很熟悉了, 这里就不赘述了. (算了 uniform 还是提一嘴, 意思是我们需要 pointwise limit 的收敛速度也是 uniform 的, 即对任意的 $\epsilon > 0$, 都存在一个 $N$ 使得对于所有的 $n \geq N$ 和所有的 $\omega$, 都有 $|X_n(\omega) - X(\omega)| < \epsilon$, 是一个严格强于 pointwise 的收敛方式. )

**Def 4.1 (RV 序列的三种收敛方式)**

- **converge a.s. (almost surely)** 或称 converge with probability 1:
$$\mathbb{P}\left(\lim_{n\to\infty} X_n = X\right) = 1$$
即:
$$\mathbb{P}\left(\left\{\omega \in \Omega : \lim_{n\to\infty} X_n(\omega) = X(\omega)\right\}\right) = 1$$
也就是说 $X_n$ 的 a.e. pointwise limit 是 $X$.
- **converge in $L^p$**: 对于 $L^p$-integrable 的 random variables sequence $X_n$ 和 $X$, 我们称 $X_n \xrightarrow{L^p} X$, 如果
$$\lim_{n\to\infty} \mathbb{E}\left[|X_n - X|^p\right] = 0$$
即: 这个 seq of RVs 与这个 limit function 之间的 $L^p$ distance 收敛到 0; 也就是它们的偏差 as a random variable, 其 $p$-th moment 收敛到 0.
- **converge in probability**: 对于任意的 $\epsilon > 0$, 如果
$$\lim_{n\to\infty} \mathbb{P}(|X_n - X| > \epsilon) = 0$$
即 $X_n$ 与 $X$ 之间的偏差超过 $\epsilon$ 的概率收敛到 0. ♣

## 4.3 Borel-Cantelli Lemma

## 4.4 Laws of Large Numbers

### 4.4.1 weak and strong LLN

下面是概率论中最重要的定律之一: 大数定律 (Laws of Large Numbers, LLN).
它证明的是一个十分符合直觉的结论: 一个 random variable 的 sample mean (即 $n$ 个 i.i.d. 的 copy 的均值), 随着 sample 数量的增加, 会 converge to 它的 expectation.
就是说: 我们重复做一个相同的实验并取结果的平均值, 当我们做的实验足够多时, 这个平均值就会非常接近于这个实验的 expectation, 也就是理论的均值.

例如最经典的例子就是抛硬币: 我们连续抛 $n$ 次一个公平的硬币, 记录每次抛出正面 (记为 1) 或者反面 (记为 0), 然后计算这些结果的平均值, 随着 $n$ 的增加, 这个平均值会趋近于 0.5, 等于理论的 expectation (这是个 Bernouli random variable, expectation = $p$).

LLN 有两个阶段, weak LLN 和 strong LLN, weak LLN 证明的是这个 convergence 是 in probability 的, 而 strong LLN 证明的是这个 convergence 是 a.s. 的. 就是说 strong LLN 是严格强于 weak LLN 的.

**Theorem 4.9 (weak Law of Large Numbers)**

对于一列 i.i.d. 的 random variables $\{X_i\}$, 只要这个 random variable 的 expectation 是 finite 的 $\mathbb{E}[X_1^2] < \infty$, 那么就有:

$$\frac{X_1 + X_2 + \cdots + X_n}{n} \xrightarrow{p} \mathbb{E}[X_1] \quad \text{as } n \to \infty$$

♡

**Proof** 简写 $\mu := \mathbb{E}[X_1]$, $S_n := \frac{X_1+X_2+\cdots+X_n}{n}$ for each $n$.
Let $\varepsilon > 0$. It suffices to show: $\mathbb{P}(|S_n - \mu| > \varepsilon) \to 0$ as $n \to \infty$. By Chebyshev's inequality, we have

$$\begin{aligned}\mathbb{P}\left(|S_n/n - \mu| > \varepsilon\right) &\leq \frac{\mathrm{Var}(S_n/n)}{\varepsilon^2} \\ &= \frac{1}{n^2\varepsilon^2}\left(\sum_{n=1}^{n}\mathbb{E}[|X_i - \mu|^2] + 2\sum_{1\leq i<j\leq n}\mathbb{E}[(X_i-\mu)(X_j-\mu)]\right)\end{aligned}$$

notice: 由于每个 $X_i$ 都是 i.i.d. 的, independence $\implies$ uncorrelatedness $\implies$ $\mathrm{Cov}(X,Y) = \mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y] = 0$, 因而 $\mathbb{E}[(X_i-\mu)(X_j-\mu)] = \mathbb{E}[(X_i-\mu)]\mathbb{E}[(X_j-\mu)] = 0 \cdot 0 = 0$ for each $i \neq j$.
因而

$$\mathbb{P}\left(|S_n/n - \mu| > \varepsilon\right) = \frac{1}{\varepsilon^2 n^2}\sum_{n=1}^{n}\mathbb{E}[|X_i-\mu|^2] = \frac{1}{\varepsilon^2 n}\cdot n\mathrm{Var}(X_1) \overset{n\to\infty}{\to} 0$$

**Theorem 4.10 (strong Law of Large Numbers)**

在 weak LLN4.9 的相同条件 (其实可以更弱, 让 $E[X_1] < \infty$ 即可) 下, 我们其实可以得到一个更强的结论:

$$\frac{X_1 + \ldots + X_n}{n} \xrightarrow{\text{a.s.}} \mathbb{E}\left[X_1\right], \quad \text{as } n \to \infty$$

♡

**Proof** For simplicity, 我们不证明更弱的条件 ($E[X_1] < \infty$) 下的 strong LLN 了. 只沿用相同的条件.
简写 $\mu := \mathbb{E}[X_1]$, $\sigma^2 := \mathrm{Var}(X_1)$, $S_n := \frac{X_1+X_2+\cdots+X_n}{n}$ for each $n$, 以及

$$Y_n := \frac{S_n}{n} - \mu$$

我们将要证明: $Y_n \xrightarrow{a.s.} 0$.
首先, 在 weak LLN 的 proof 中, 我们已经证明了:

$$\mathbb{E}(Y_n) = 0, \quad \mathbb{E}[Y_n^2] = \frac{\sigma^2}{n}$$

我们发现: 当我们只采样 $n^2$ indexed 的时候, 它们的 expectation 的 sum 是 finite 的, by p-test (因为 $\sum_{n=1}^{\infty}\frac{1}{n^p}$ 收敛当且仅当 $p > 1$), 即:

$$\mathbb{E}\left[\sum_{n=1}^{+\infty} Y_{n^2}^2\right] = \sum_{n=1}^{+\infty}\mathbb{E}\left[Y_{n^2}^2\right] = \sum_{n=1}^{+\infty}\frac{\sigma^2}{n^2} < \infty$$

先考虑所有 $Y_n$ 都非负的 case. 我们知道: expectation of 一个 non-negative random variable 是 finite 的, 就

imply 它是 a.e. finite 的. 因而

$$\sum_{n=1}^{+\infty} Y_{n^2}^2 < \infty \quad \text{a.s.}$$

因而

$$\lim_{n\to\infty} Y_{n^2} = 0 \quad \text{a.s.}$$

意味把在 $1, 4, 9, 16...$ 这些 index 的 $Y_i$ 求 average, 确实收敛到了 $\mu$.
而我们可以通过 squeeze theorem 得到 general case: 对于任意正整数 $k$, 总能找到一对平方数把它夹在中间. 比如令 $n^2 < k < (n+1)^2$.
我们发现:

$$\frac{S_{n^2}}{(n+1)^2} \le \frac{S_k}{k} \le \frac{S_{(n+1)^2}}{n^2}$$

notice: $\frac{S_{n^2}}{(n+1)^2} = \frac{S_{n^2}}{n^2} \cdot \frac{n^2}{(n+1)^2}$, 前向 converge to $\mu$, 后向 converge to 1, 因而 $\frac{S_{n^2}}{(n+1)^2} \to \mu$, 后面那个也同理. 因而夹逼得到 $S_k/k \to \mu$. 从而得证.
General case:

$$X_n = \max\{X_n, 0\} - \max\{-X_n, 0\} =: X_n^+ - X_n^-$$

因而

$$\frac{X_1 + \ldots + X_n}{n} = \frac{X_1^+ + \ldots + X_n^+}{n} - \frac{X_1^- + \ldots + X_n^-}{n} \xrightarrow{\text{a.s.}} \mathbb{E}\left[X_1^+\right] - \mathbb{E}\left[X_1^-\right] = \mathbb{E}\left[X_1\right]$$

得证.
**Remark** 我们要求 $\mathbb{E}[|X_1|]$ 是 finite 的, 或者 $\mathbb{E}[|X_1|^2]$ 是 finite 的, 并不是一个硬性的条件, 只是结果确实 converge to $\mathbb{E}[X_1]$ 这个 finite value 的条件.
实际上在 $\mathbb{E}[X_1]$ infinite (等于 $\infty$ 或者 $-\infty$) 时, 我们会得到这个 average 发散, 因而也是和 $\mathbb{E}[X_1]$ 一样, 只不过不是 converge 而是 diverge.
此处不证明了.

### 4.4.2 application: Monte Carlo methods

任何利用 LLN 来近似计算一个 quantity 的方法, 都可以称之为 Monte Carlo 方法.
它的核心思想是:

- 选择一个随机变量, 其 expectation 等于我们要计算的 quantity.
- 大量重复采样这个随机变量, 并计算样本的平均值
- 根据大数定律, 这个平均值近似于我们要计算的 quantity.
- 我们可以用 Chebyshev's inequality 来给出这个近似的误差 bound.

**Example 4.1** 估算 $\pi$ 我们令 $X, Y \sim U([-1, 1])$
那么

$$\mathbb{E}\left[\mathbf{1}_C(X,Y)\right] = \int_{-1}^{1}\int_{-1}^{1} \mathbf{1}_C(x,y) f_{X,Y}(x,y)dxdy = \frac{1}{4}\int_{-1}^{1}\int_{-1}^{1} \mathbf{1}_C(x,y)dxdy = \frac{\pi}{4}$$

注意我们每次随机采样 $X, Y$ 的时候, 都是在 $[-1, 1] \times [-1, 1]$ 这个正方形里随机选一个点, 即创建了一个 random variable $(X_i, Y_i)$ 并进行观测.

根据 LLN, 不论单次的采样结果如何, 我们都可以得到

$$\lim_{n\to\infty} \frac{\mathbf{1}_C(X_1,Y_1)+\ldots+\mathbf{1}_C(X_n,Y_n)}{n} = \frac{\pi}{4}, \quad \text{a.s.}$$

我们还可以用 Chebyshev's inequality 来给出这个近似的误差 bound:

$$\mathbb{P}\left(|4S_n/n-\pi|>\varepsilon\right) \le \frac{\operatorname{Var}(4S_n/n)}{\varepsilon^2} = \frac{4^2}{n^2\varepsilon^2}\operatorname{Var}\left(\sum_{i=1}^n \mathbf{1}_C(X_i,Y_i)\right) = \frac{16}{n\varepsilon^2}\operatorname{Var}\left(\mathbf{1}_C(X_1,Y_1)\right) \approx \frac{1}{n\varepsilon^2}$$

因而当 $n$ 足够大时, 几乎一定可以得到目标值.

```python
import random
def estimate_pi(n):
    S_n = 0 # This step 1
    for _ in range(n):
        # Here is step 2 (and 3)
        X = random.uniform(-1, 1)
        Y = random.uniform(-1, 1)
        # Check if the point is inside the unit circle
        if X**2 + Y**2 <= 1:
            S_n += 1
    pi_estimate = 4 * S_n / n
    return pi_estimate
# Example usage
n = 1000000
pi_approx = estimate_pi(n)
print(pi_approx)
```

### 4.4.3 application: Bernstein Polynomials

### 4.4.4 application: Hypothesis testing