Module 5 Central Limit Theorem

5.1 convergence in distribution

Def 5.1 (convergence in distribution)

我们称一个 seq of random variables $\{X_n\}$ converge in distribution to a random variable X, 写作 $X_n \xrightarrow{d} X$, 如果 X 的分布函数 F_X 下所有右连续的 x (即 $F_X(x) = F_X(x-)$), 都有

$$\lim_{n\to\infty} F_{X_n}(x) = F_X(x)$$

♣

Remark Convergence in distribution 的意思就是: 随着 n 越来越大, X_n 的分布是否越来越接近 X 的分布. 这是一个非常弱的收敛概念, 因为它甚至**不要求 X_n 和 X 在同一个概率空间上定义**, 也不要求 X_n 和 X 之间有任何关系. 只需要分布函数收敛即可.

并且 notice: 并不要求对所有点 x 都有 $F_{X_n}(x) \to F_X(x)$, 而是只要求对 X 的分布函数 F_X 下所有右连续的点 x. 这是因为如果不加这个限制, 很多直观上应该收敛的情况在数学上就会失败.

比如: 令 $X_n = 1/n$, 一个 constant random variable, 那么 X_n 的分布函数 F_{X_n} 是一个 step function. 但是在 $x = 0$ 处, $F_{X_n}(0) = 0$ for all n, 因而 $\lim_{n\to\infty} F_{X_n}(0) = 0$.

而 $F_X(0) = 1$.

所以对于这种跳跃不连续点, 如果不跳过, 那么就会得出 X_n 不收敛于 X 的错误结论. 但是我们知道, 分布函数作为一个单调递增的函数, 是 a.e. continuous 的, 因而这些点是可以忽略掉的.

5.2 Characterization of a distribution

5.2.1 moment generating function

Def 5.2 (moment generating function)

对于一个随机变量 X, 其 moment generating function (MGF) 定义为

$$M_X(t) = \mathbb{E}[e^{tX}], \quad t \in \mathbb{R}$$

♣

Remark 为什么这个东西叫做 moment generating function 呢? 因为如果 $M_X(t)$ 在 $t = 0$ 的某个 neighborhood 内存在, 那么我们可以通过对 $M_X(t)$ 求导来得到 X 的各阶矩:

Proposition 5.1 ()

如果 $M_X(t)$ 在 $t = 0$ 的某个 neighborhood 内存在, 则 X 的 n 阶矩可以表示为

$$\mathbb{E}[X^n] = M_X^{(n)}(0)$$

其中 $M_X^{(n)}(0)$ 表示 $M_X(t)$ 在 $t = 0$ 处的 n 阶导数.

♠

5.2.2 characteristic function

5.3 Central Limit Theorem

Theorem 5.1 (Lindeberg-Levy Central Limit Theorem)

对于任意一个 seq of i.i.d. random variables $\{X_i\}$ with mean μ and variance $\sigma^2 < \infty$, set $S_n = X_1 + X_2 + \cdots + X_n$ for each n.
我们有:

$$\frac{S_n - n\mu}{\sqrt{n\sigma^2}} \xrightarrow{d} N(0,1)$$

♡

Remark LLN 告诉我们, 当 n 越来越大时, S_n/n 越来越接近 μ. 每个 X_i 随机取样, 不论结果如何, 其平均值大概率都是 μ.

CLT 则是进一步告诉我们这个接近的过程是如何发生的: 随着 n 越来越大, S_n 的分布会越来越接近一个正态分布, 且波动的幅度 (标准差) 数量级为 $\sqrt{n}$. **因而平均值 S_n/n 的分布会越来越接近一个均值为 μ, 标准差为 $\sigma/\sqrt{n}$ 的正态分布**

$$\frac{S_n}{n} = \mu + \frac{\sigma}{\sqrt{n}} Z, \quad Z \sim N(0,1)$$

随着 n 越来越大, 这个标准差会越来越小, 因而其极限坍缩为一个 constant μ.

Remark CLT 的一个主要的应用价值, 就是可以用来估计由多个 i.i.d. 随机因素共同作用的现象的分布. 统计学中常用于对 confidence interval 的估计, 以及 hypothesis testing, 通过计算如 $\mathbb{P}\left(\frac{S_n - n\mu}{\sqrt{n\sigma^2}} \in A\right)$ 这种形式的概率来进行推断.

在进行证明前, 我们先看一些 applications of CLT. 可能会帮助我们更好地理解 CLT 的意义.

5.3.1 applications of CLT

Example 5.1 (判断 coin 是否 fair)
我们有两个 coins, 想要判断它们是否是 fair coin. 我们可以 toss 这个 coin n 次, 记录下每次 toss 的结果, 记为 $X_1, X_2, \cdots, X_n$, 其中 $X_i = 1$ if the i-th toss is heads.
现在: 观测到第一个 coin 100 次 toss 中有 38 次是 heads, 第二个 coin 100 次 toss 中有 43 次是 heads.
Sol. 假设这两个 coins 是 fair coin. 那么 X_i 是 i.i.d. Bernoulli random variables with parameter $p = 0.5$, 因而 $\mu = p = \frac{1}{2}$, $\sigma^2 = p(1-p) = \frac{1}{4}$. 从而根据 CLT,

$$\mathbb{P}(S_100 < 38) = \mathbb{P}\left(\frac{S_{100} - 100 \cdot \frac{1}{2}}{\sqrt{100 \cdot \frac{1}{4}}} < \frac{38 - 100 \cdot \frac{1}{2}}{\sqrt{100 \cdot \frac{1}{4}}}\right) \approx \mathbb{P}\left(Z < \frac{38-50}{5}\right) \approx \mathbb{P}(Z < -2.4) \approx 0.0082 < 0.01$$

因而这个第一个 coin 很可能不是 fair coin. 同样的方法计算出 $\mathbb{P}(S_{100} \leq 43) \approx 0.0887$, 因而第二个 coin 虽然也可疑不是 fair coin, 但是不如第一个 coin 可疑. 如果以 0.05 作为显著性水平, 那么我们可以拒绝第一个 coin 是 fair coin 的假设.

Example 5.2 (样本量需求的计算) 工厂生产了一批电线, 我们想知道它们的平均断裂强度 μ 是多少. 遂抽取 n 根电线进行测量, 得到 $X_1, ..., X_n$, 然后计算它们的样本平均值 $\overline{X}_n$ 来估计 μ.
已知量: 强度的方差 $\sigma^2 = 1/10$.; 我们想估计的是 μ 的值. 并且我们希望我们的估计是准的, in the sense that: 误差 $|\overline{X}_n - \mu|$ 不超过 0.01 的概率至少为 0.95.
Sol. 我们要达到: $\mathbb{P}(|\overline{X}_n - \mu| \leq 1/100)$.
我们要把它转成标准的 normal distribution 的形式, 即 $Z = \frac{S_n - n\mu}{\sqrt{n\sigma^2}}$ 的形式.
于是我们把 $\overline{X}_n - \mu$ 写为 $\frac{S_n}{n} - \mu$, 然后两边同时乘 $\frac{\sqrt{n}}{\sigma}$. 右边的常数项也做相同的变换: $\frac{1/100}{\sigma/\sqrt{n}} = \frac{\sqrt{n}}{100\sigma}$.
于是原式变为:

$$\mathbb{P}(|Z| \leq \frac{\sqrt{n}}{100\sigma}) \approx 0.95$$

对于正态分布我们知道

$$\mathbb{P}(|Z| \leq x) = 2\Phi(x) - 1$$

于是想要:

$$2\Phi\left(\frac{\sqrt{n}}{100\sigma}\right) - 1 \geq 0.95 \implies \Phi\left(\frac{\sqrt{n}}{100\sigma}\right) \geq 0.975$$

通过查表我们知道当 $\Phi(z) = 0.975$ 时, $z \approx 1.96$. 因此要求 $\frac{\sqrt{n}}{100\sigma} \geq 1.96$, 解得至少需要 $n \geq (61.98)^2 \approx 384.16$, floor 一下得到 $n \geq 385$.
Remark 这里的应用正是我们开头说的: LLN 告诉我们, 当 n 越来越大时, S_n/n 越来越接近 μ. 每个 X_i 随机取样, 不论结果如何, 其平均值大概率都是 μ; 而 CLT 则是进一步告诉我们这个接近的过程是如何发生的:

$$\frac{S_n}{n} = \mu + \frac{\sigma}{\sqrt{n}}Z, \quad Z \sim N(0,1)$$

随着 n 越来越大, 这个标准差会越来越小, 因而其极限坍缩为一个 constant μ. **因而, 我们可以通过 CLT 来得到: 我们要用样本均值来估计分布的真实均值的话, 在一定的置信水平下, 需要多少样本量 n 才能保证我们的估计是准的.**

5.3.2 Berry-Esseen Theorem: CLT 的收敛速度

之前的例子中, 我们都使用了 $\approx$ 表示: 我们直接把此时的分布近似当作了一个 normal distribution, 当作

Theorem 5.2 (Berry-Esseen Theorem)