

Module 5 Central Limit Theorem

5.1 convergence in distribution

Def 5.1 (convergence in distribution)

我们称一个 seq of random variables $\{X_n\}$ converge in distribution to a random variable X , 写作 $X_n \xrightarrow{d} X$, 如果 X 的分布函数 F_X 下所有右连续的 x (即 $F_X(x) = F_X(x-)$), 都有

$$\lim_{n \rightarrow \infty} F_{X_n}(x) = F_X(x)$$



Remark Convergence in distribution 的意思就是: 随着 n 越来越大, X_n 的分布是否越来越接近 X 的分布. 这是一个非常弱的收敛概念, 因为它甚至不要求 X_n 和 X 在同一个概率空间上定义, 也不要求 X_n 和 X 之间有任何关系. 只需要分布函数收敛即可.

并且 notice: 并不要求对所有点 x 都有 $F_{X_n}(x) \rightarrow F_X(x)$, 而是只要求对 X 的分布函数 F_X 下所有右连续的点 x . 这是因为如果不加这个限制, 很多直观上应该收敛的情况在数学上就会失败.

比如: 令 $X_n = 1/n$, 一个 constant random variable, 那么 X_n 的分布函数 F_{X_n} 是一个 step function. 但是在 $x = 0$ 处, $F_{X_n}(0) = 0$ for all n , 因而 $\lim_{n \rightarrow \infty} F_{X_n}(0) = 0$.

而 $F_X(0) = 1$.

所以对于这种跳跃不连续点, 如果不跳过, 那么就会得出 X_n 不收敛于 X 的错误结论. 但是我们知道, 分布函数作为一个单调递增的函数, 是 a.e. continuous 的, 因而这些点是可以忽略掉的.

5.2 Characterization of a distribution

5.2.1 moment generating function

Def 5.2 (moment generating function)

对于一个随机变量 X , 其 moment generating function (MGF) 定义为

$$M_X(t) = \mathbb{E}[e^{tX}], \quad t \in \mathbb{R}$$



Remark 为什么这个东西叫做 moment generating function 呢? 因为如果 $M_X(t)$ 在 $t = 0$ 的某个 neighborhood 内存在, 那么我们可以通过对 $M_X(t)$ 求导来得到 X 的各阶矩:

Proposition 5.1 ()

如果 $M_X(t)$ 在 $t = 0$ 的某个 neighborhood 内存在, 则 X 的 n 阶矩可以表示为

$$\mathbb{E}[X^n] = M_X^{(n)}(0)$$

其中 $M_X^{(n)}(0)$ 表示 $M_X(t)$ 在 $t = 0$ 处的 n 阶导数.



5.2.2 characteristic function

5.3 Central Limit Theorem

Theorem 5.1 (Lindeberg-Levy Central Limit Theorem)

对于任意一个 seq of i.i.d. random variables $\{X_i\}$ with mean μ and variance $\sigma^2 < \infty$, set $S_n = X_1 + X_2 + \dots + X_n$ for each n .

我们有:

$$\frac{S_n - n\mu}{\sqrt{n\sigma^2}} \xrightarrow{d} N(0, 1)$$



Remark LLN 告诉我们, 当 n 越来越大时, S_n/n 越来越接近 μ . 每个 X_i 随机取样, 不论结果如何, 其平均值大概率都是 μ .

CLT 则是进一步告诉我们这个接近的过程是如何发生的: 随着 n 越来越大, S_n 的分布会越来越接近一个正态分布, 且波动的幅度 (标准差) 数量级为 $\sqrt{n}$. 因而平均值 S_n/n 的分布会越来越接近一个均值为 μ , 标准差为 $\sigma/\sqrt{n}$ 的正态分布

$$\frac{S_n}{n} = \mu + \frac{\sigma}{\sqrt{n}}Z, \quad Z \sim N(0, 1)$$

随着 n 越来越大, 这个标准差会越来越小, 因而其极限坍缩为一个 constant μ .

Remark CLT 的一个主要的应用价值, 就是可以用来估计由多个 i.i.d. 随机因素共同作用的现象的分布. 统计学中常用于对 confidence interval 的估计, 以及 hypothesis testing, 通过计算如 $\mathbb{P}\left(\frac{S_n - n\mu}{\sqrt{n\sigma^2}} \in A\right)$ 这种形式的概率来进行推断.

在进行证明前, 我们先看一些 applications of CLT. 可能会帮助我们更好地理解 CLT 的意义.

5.3.1 applications of CLT

Example 5.1 (判断 coin 是否 fair)

我们有两个 coins, 想要判断它们是否是 fair coin. 我们可以 toss 这个 coin n 次, 记录下每次 toss 的结果, 记为 $X_1, X_2, \dots, X_n$, 其中 $X_i = 1$ if the i -th toss is heads.

现在: 观测到第一个 coin 100 次 toss 中有 38 次是 heads, 第二个 coin 100 次 toss 中有 43 次是 heads.

Sol. 假设这两个 coins 是 fair coin. 那么 X_i 是 i.i.d. Bernoulli random variables with parameter $p = 0.5$, 因而 $\mu = p = \frac{1}{2}$, $\sigma^2 = p(1-p) = \frac{1}{4}$. 从而根据 CLT,

$$\mathbb{P}(S_{100} < 38) = \mathbb{P}\left(\frac{S_{100} - 100 \cdot \frac{1}{2}}{\sqrt{100 \cdot \frac{1}{4}}} < \frac{38 - 100 \cdot \frac{1}{2}}{\sqrt{100 \cdot \frac{1}{4}}}\right) \approx \mathbb{P}\left(Z < \frac{38 - 50}{5}\right) \approx \mathbb{P}(Z < -2.4) \approx 0.0082 < 0.01$$

因而这个第一个 coin 很可能不是 fair coin. 同样的方法计算出 $\mathbb{P}(S_{100} \leq 43) \approx 0.0887$, 因而第二个 coin 虽然也可疑不是 fair coin, 但是不如第一个 coin 可疑. 如果以 0.05 作为显著性水平, 那么我们可以拒绝第一个 coin 是 fair coin 的假设.

Example 5.2 (样本量需求的计算) 工厂生产了一批电线, 我们想知道它们的平均断裂强度 μ 是多少. 遂抽取 n 根电线进行测量, 得到 $X_1, \dots, X_n$, 然后计算它们的样本平均值 $\bar{X}_n$ 来估计 μ .

已知量: 强度的方差 $\sigma^2 = 1/10$; 我们想估计的是 μ 的值. 并且我们希望我们的估计是准的, in the sense that: 误差 $|\bar{X}_n - \mu|$ 不超过 0.01 的概率至少为 0.95.

Sol. 我们要达到: $\mathbb{P}(|\bar{X}_n - \mu| \leq 1/100)$.

我们要把它转成标准的 normal distribution 的形式, 即 $Z = \frac{S_n - n\mu}{\sqrt{n\sigma^2}}$ 的形式.

于是我们把 $\bar{X}_n - \mu$ 写为 $\frac{S_n}{n} - \mu$, 然后两边同时乘 $\frac{\sqrt{n}}{\sigma}$. 右边的常数项也做相同的变换: $\frac{1/100}{\sigma/\sqrt{n}} = \frac{\sqrt{n}}{100\sigma}$. 于是原式变为:

$$\mathbb{P}(|Z| \leq \frac{\sqrt{n}}{100\sigma}) \approx 0.95$$

对于正态分布我们知道

$$\mathbb{P}(|Z| \leq x) = 2\Phi(x) - 1$$

于是想要:

$$2\Phi\left(\frac{\sqrt{n}}{100\sigma}\right) - 1 \geq 0.95 \implies \Phi\left(\frac{\sqrt{n}}{100\sigma}\right) \geq 0.975$$

通过查表我们知道当 $\Phi(z) = 0.975$ 时, $z \approx 1.96$. 因此要求 $\frac{\sqrt{n}}{100\sigma} \geq 1.96$, 解得至少需要 $n \geq (61.98)^2 \approx 384.16$, floor 一下得到 $n \geq 385$.

Remark 这里的应用正是我们开头说的: LLN 告诉我们, 当 n 越来越大时, S_n/n 越来越接近 μ . 每个 X_i 随机取样, 不论结果如何, 其平均值大概率都是 μ ; 而 CLT 则是进一步告诉我们这个接近的过程是如何发生的:

$$\frac{S_n}{n} = \mu + \frac{\sigma}{\sqrt{n}}Z, \quad Z \sim N(0, 1)$$

随着 n 越来越大, 这个标准差会越来越小, 因而其极限坍缩为一个 constant μ . 因而, 我们可以通过 CLT 来得到: 我们要用样本均值来估计分布的真实均值的话, 在一定的置信水平下, 需要多少样本量 n 才能保证我们的估计是准的.

5.3.2 Berry-Esseen Theorem: CLT 的收敛速度

之前的例子中, 我们都使用了 $\approx$ 表示: 我们直接把此时的分布近似当作了一个 normal distribution, 来计算一些概率.

但是: 这两个分布的近似行为的本身有多么精准?

下面有一个 theorem 刻画了这件事.

Theorem 5.2 (Berry-Esseen Theorem)

给定一个 seq of i.i.d. random variables $\{X_i\}$ with mean μ and variance $\sigma^2 < \infty$, 以及 $\mathbb{E}[|X_i - \mu|^3] = \rho < \infty$, set $S_n = X_1 + X_2 + \dots + X_n$, 我们有: 对于任意 $x \in \mathbb{R}$,

$$\left| \mathbb{P}\left(\frac{S_n - n\mu}{\sqrt{n\sigma^2}} \leq x\right) - \Phi(x) \right| \leq \frac{3\rho}{\sigma^2\sqrt{n}}$$



Remark 给定一个 number of samples n , 我们可以给出此时的真实概率与正态近似值之间的差值的一个 upper bound.

并且, 这个 bound 不是概率意义上的 bound, 而是一个 **deterministic bound**, 没有任何的随机性; 并且是 **uniform across all x 的 bound**.

这是因为这里本身就是两个概率的值之间的差, 而不是样本之间的差. 因而其实这是一个非常强大的结论, 表面我们用正态分布近似估计出的概率和真实的概率之间的差值是 **deterministically controllable** 意义上非常小的.

我们马上可以想到: 对于控制样本数量来达到某个置信水平的问题, 这是一个非常有用的工具, 因为它告诉我们, 当 n 足够大时, 我们用正态分布近似估计出的概率和真实的概率之间的差值是非常小并且可以控制的.

并且, 这个控制应该还是比较精准的. 因为相比其他的控制方法: **Chebyshev** 只需要 **first, second order moments** 的信息; **Hoeffding** 只需要有界性的假设, 甚至不需要知道分布的任何 **moment** 信息; 而 **Berry-Esseen** 需要 **third order moment** 的信息, 因此它应该能够给一个更精准的控制.

Proof //TODO: □

Example 5.3 一个工厂生产电子元件, 每个原件有概率是有缺陷的.

令

$$X_i = \begin{cases} 1, & \text{if the } i \text{ th tested component is defective,} \\ 0, & \text{otherwise.} \end{cases}$$

并假设 i.i.d. with parameter

$$\mathbb{P}(X_i = 1) = p$$

其中 p 是一个未知的参数.

工厂方面表示这个 process 是 under control 的, 并给出了假设: $H_0 : p \leq 0.02$.

为了验证这个假设, 一个 quality control manager 需要从生产线上需要随机 n 个元件进行测试, 并估计出 p 的值 by 样本均值:

$$\hat{p}_n := \frac{1}{n} \sum_{i=1}^n X_i$$

我们希望这个估计的误差最多为 0.005, 并且这个误差的置信度至少为 0.99, 即我们希望:

$$\mathbb{P}(|\hat{p}_n - p| > 0.005) \leq 0.01$$

那么我们至少需要多少样本量 n 来达到这个要求呢?

Sol. 首先计算样本均值 $\hat{p}_n$ 的 mean 和 variance:

$$\mathbb{E}[\hat{p}_n] = p, \quad \text{Var}(\hat{p}_n) = \frac{1}{n^2} \sum_{i=1}^n \text{Var}(X_i) = \frac{p(1-p)}{n}$$

此时我们三个办法:

- 办法 1: **Chebyshev's inequality**.

$$\mathbb{P}(|\hat{p}_n - p| \geq \varepsilon) \leq \frac{\text{Var}(\hat{p}_n)}{\varepsilon^2} = \frac{p(1-p)}{n\varepsilon^2}$$

由于 $p(1-p) \leq 1/4$ for any $p \in [0, 1]$, 式子可以进一步控制为

$$\mathbb{P}(|\hat{p}_n - p| \geq \varepsilon) \leq \frac{1}{4n\varepsilon^2}$$

我们希望此概率不超过 0.01, 并且 $\varepsilon = 0.005$, 那么进一步得到需要

$$\frac{1}{4n(0.005)^2} \leq 0.01$$

解得至少需要 $n \geq 1000000$.

• 办法 2: **Hoeffding's inequality**.

由于 $0 \leq X_i \leq 1$, 我们可以直接使用 Hoeffding's inequality 来控制:

$$\mathbb{P}(|\hat{p}_n - p| \geq \varepsilon) \leq 2e^{-2n\varepsilon^2}$$

我们 require 了 $2e^{-2n(0.005)^2} \leq 0.01$, 因而可以解得

$$n \geq \frac{|\ln(0.005)|}{2(0.005)^2} \approx 106,000$$

• 办法 3: **Berry-Esseen Theorem**.

首先我们假设报告的 p 的值 0.02 是正确的, 从而可以计算出:

$$\mathbb{E}[X_1] = p, \quad \sigma^2 := \text{Var}(X_1) = p(1-p) = 0.0196, \quad \sigma = 0.14$$

并且, 由于 $|X_1 - p| \leq 1$, 我们知道偏度 $\rho := \mathbb{E}[|X_1 - p|^3] < \infty$.

因而可以应用 Berry-Esseen Theorem. 我们希望:

$$\mathbb{P}(|\hat{p}_n - p| \leq \varepsilon) = \mathbb{P}(|S_n - np| \leq n\varepsilon) \geq 0.99, \quad \varepsilon = 0.005$$

等价于

$$\mathbb{P}\left(\left|\frac{S_n - np}{\sigma\sqrt{n}}\right| \leq \frac{\varepsilon\sqrt{n}}{\sigma}\right) \geq 0.99$$

Berry-Esseen Theorem 可以得到: 对于任意的 $x > 0$, 有

$$\mathbb{P}\left(\left|\frac{S_n - np}{\sigma\sqrt{n}}\right| \leq x\right) \geq 2\Phi(x) - 1 - \frac{6\rho}{\sigma^2\sqrt{n}}$$

因而我们需要选择 n s.t.

$$2\Phi\left(\frac{\varepsilon\sqrt{n}}{\sigma}\right) - 1 - \frac{6\rho}{\sigma^2\sqrt{n}} \geq 0.99$$

忽略掉 $\frac{6\rho}{\sigma^2\sqrt{n}}$ 这个很小的项 (计算可以再精细地选择 n), 我们也可以得到:

$$\frac{\varepsilon\sqrt{n}}{\sigma} \geq z_{0.995} \approx 2.576$$

因而至少需要 $n \geq 5200$.

我们可以看到

- 通过 Chebyshev's inequality 来控制, 我们需要的样本量是 100 万级别的;
- 通过 Hoeffding's inequality 来控制, 我们需要的样本量是 10 万级别的;
- 通过 Berry-Esseen Theorem 来控制, 我们需要的样本量是 5000 级别的, 显然更为高效.

不过, 这个结果是基于我们假设 $p = 0.02$ 的前提下得到的. Chebyshev 的逻辑 (保守估计): 我不相信厂家的任何话, 我要建立一个无论真实 p 是多少都绝对成立的置信区间. 所以我必须用最差的情况 $p = 0.5$ 来算 n . CLT/Berry-Esseen 的逻辑 (假设检验): 厂家宣称 $p \leq 0.02$. 在统计学中, 我们通常先假设这个宣称是正确的 (即 H_0 假设). 如果我们用在这个假设下得出的需要的样本量 $n = 5200$ 去测, 发现结果远超 0.02, 那我们就直接推翻厂家的说法.

5.3.3 proof of CLT